BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC ĐẠI NAM



NHÓM 9

Hoàng Quang Nam	1871020407
Bùi Huy Bình	1871020080
Hoàng Nhật Huy	1871020296
Nguyễn Văn Linh	1871020356

DỰ ĐOÁN SINH VIÊN CÓ NGUY CƠ BỎ HỌC

BÁO CÁO BÀI TẬP LỚN FIT4013

HÀ NỘI, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC ĐẠI NAM



NHÓM 9

Hoàng Quang Nam	1871020407
Bùi Huy Bình	1871020080
Hoàng Nhật Huy	1871020296
Nguyễn Văn Linh	1871020356

KHÓA: K18

DỰ ĐOÁN SINH VIÊN CÓ NGUY CƠ BỎ HỌC

BÁO CÁO BÀI TẬP LỚN FIT4013

NGÀNH: CÔNG NGHỆ THÔNG TIN

CHUYÊN NGÀNH: PHÁT TRIỂN PHẦN MỀM

GIẢNG VIÊN HƯỚNG DẪN: ThS. Lê Thị Thùy Trang

HÀ NỘI, NĂM 2026

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT

CV	Cross-Validation – kiểm định chéo
DSS	Decision-Support System – hệ thống hỗ trợ ra quyết định
EDA	Exploratory Data Analysis – khám phá dữ liệu
FN	False Negative – âm tính giả (bỏ sót ca thực tế)
FP	False Positive – dương tính giả (cảnh báo nhầm)
IQR	Interquartile Range – khoảng tứ phân vị
K-NN	K-Nearest Neighbors – thuật toán k láng giềng gần nhất
PII	Personally Identifiable Information – thông tin nhận dạng cá nhân
TP	True Positive – dương tính thật
UCI	University of California, Irvine (kho dữ liệu học máy chuẩn)
Zero-R	Zero Rule – mô hình cơ sở dự đoán toàn bộ theo lớp đa số

DANH MỤC CÁC BẢNG, SƠ ĐỒ, HÌNH

BẢNG:

Tên bảng	Trang
Bảng 1.1. Ý nghĩa và kiểu dữ liệu các cột chính	3
Bảng 1.2. Ý nghĩa và kiểu dữ liệu 18 cột không dùng làm đầu vào	3
Bảng 1.3. Số lượng mẫu của từng lớp	4
Bảng 1.4. Ma trận tương quan Pearson giữa 4 biến số (tập train)	8
Bảng 3.1. Các tệp và thư mục chính của dự án	18
Bảng 4.1. Cấu hình siêu tham số tối ưu chọn theo 5-fold CV trên tập train . .	22
Bảng 4.2. So sánh tổng hợp các mô hình trên tập kiểm thử (885 mẫu)	23
Bảng 4.3. Precision, Recall và F1-score theo từng lớp trên tập test	23
Bảng 4.4. Ablation luồng B: macro-F1 trung bình trên 5 fold train	27
Bảng 5.1. Ưu và nhược điểm của các pipeline tiền xử lý và mô hình phân loại	28
Bảng 5.2. Top 10 đặc trưng quan trọng nhất trong mô hình Cây quyết định (B / Cây)	29

SƠ ĐỒ:

Tên sơ đồ	Trang
Sơ đồ 2.1. Quy trình xử lý và đánh giá của nhóm	14

HÌNH:

Tên hình	Trang
Hình 1.1. Phân bố nhãn trên tập huấn luyện	5
Hình 1.2. Phân phối các biến số được chọn trên tập train	6
Hình 1.3. Box plot các biến số trên tập train; vạch màu là trung vị, hộp là khoảng IQR; râu tới điểm quan sát xa nhất trong ngưỡng $1{,}5 \times$ IQR, chấm là ngoại lệ.	7
Hình 1.4. Heatmap tương quan Pearson giữa 4 biến số (tập train). Giá trị trong ô là hệ số tương quan.	8
Hình 1.5. Số mẫu theo mã ngành trong tập train	9
Hình 1.6. Phân bố các biến phân loại chính (tập train): giới tính, ca học và hình thức đăng ký (top 5 mã). Nhãn cột ghi số lượng mẫu tương ứng.	9
Hình 1.7. Tỷ lệ Dropout theo nhóm trên tập train (ngành và hình thức đăng ký hiển thị các mã phổ biến nhất).	12
Hình 4.1. Macro-F1 CV theo từng giá trị k (K-NN) và độ sâu `max_depth` (Cây quyết định); các siêu tham số còn lại được tối ưu trong lưới.	22
Hình 4.2. So sánh Macro-F1 và F1-score từng lớp giữa các tổ hợp thử nghiệm.	24
Hình 4.3. Ma trận nhầm lẫn của 4 tổ hợp thử nghiệm trên tập test (hàng: nhãn thực, cột: dự đoán).	25

MỤC LỤC

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT . . . . . **i**

DANH MỤC CÁC BẢNG, SƠ ĐỒ, HÌNH . . . . . **ii**

MỞ ĐẦU . . . . . **vi**

CHƯƠNG 1. Đặt vấn đề và phân tích dữ liệu **1**

1.1. Bối cảnh và mục tiêu **1**

1.2. Nguồn và cấu trúc dữ liệu **2**

1.3. Phân bố nhãn **4**

1.4. Khám phá các đặc trưng **5**

1.4.1. Biến số 5

1.4.2. Tương quan giữa các biến số 7

1.4.3. Biến phân loại 8

1.5. Thông tin thiếu và giới hạn của dữ liệu **9**

1.6. Phân tích cột gây rò rỉ nhãn **10**

1.7. Quan hệ đặc trưng và nhãn trên train và giả thuyết ban đầu **11**

CHƯƠNG 2. Thiết kế giải pháp và quy trình học máy **14**

2.1. Thời điểm dự đoán và lựa chọn đặc trưng **14**

2.2. Chia dữ liệu và kiểm soát rò rỉ **15**

2.3. Hai luồng tiền xử lý (Luồng A và Luồng B) **15**

2.4. Không gian siêu tham số và thuật toán sử dụng **16**

2.5. Các độ đo đánh giá và tiêu chí tối ưu **17**

CHƯƠNG 3. Phân tích mã nguồn và chức năng **18**

3.1. Cấu trúc chương trình **18**

3.2. Đọc và kiểm tra dữ liệu **18**

3.3. Xây dựng pipeline và trích xuất đoạn mã then chốt **19**

3.3.1. Xây dựng bộ tiền xử lý với ColumnTransformer 19

3.3.2. Tối ưu hóa siêu tham số với GridSearchCV 19

3.4. Cách kiểm tra kết quả và ứng dụng demo **20**

CHƯƠNG 4. Thử nghiệm và kết quả **21**

4.1. Các mô hình Baseline đối chứng **21**

4.2. Kết quả kiểm định chéo và lựa chọn siêu tham số **21**

4.3. Kết quả trên tập test **23**

4.4. Phân tích Ma trận nhầm lẫn đầy đủ và kiểm tra đối chứng **24**

4.4.1. Precision và Recall của lớp Dropout . . . 25
4.4.2. Phân tích dòng chuyển dịch lỗi giữa các lớp . . . 25
4.5. So sánh Luồng A và Luồng B: Tác động của tiền xử lý . . . **26**
4.6. Ablation trên các fold train . . . **26**
4.7. Khoảng biến thiên mô tả trên tập test . . . **27**
4.8. ROC-AUC cho cấu hình B/K-NN . . . **27**
CHƯƠNG 5. Thảo luận và phân tích lỗi . . . **28**
5.1. So sánh ưu và nhược điểm của các pipeline và mô hình . . . **28**
5.1.1. Độ nhạy của cây quyết định . . . 28
5.2. Phân tích độ quan trọng của đặc trưng (Feature Importances) . . . **29**
5.3. Phân tích phân bố lỗi theo nhóm nhân khẩu và ngành học . . . **29**
5.3.1. Phân tích lỗi theo nhóm tuổi . . . 30
5.3.2. Phân tích lỗi theo ngành học (Course) . . . 30
5.4. Bản chất khó khăn của lớp sinh viên đang theo học (Enrolled) . . . **30**
5.5. Tác động thực tế của các loại sai lầm trong giáo dục . . . **31**
5.6. Giới hạn nghiên cứu . . . **31**
CHƯƠNG 6. Tổng kết và khuyến nghị ứng dụng . . . **32**
6.1. Kết quả và giới hạn . . . **32**
6.2. Đề xuất sử dụng trong bối cảnh nhà trường . . . **32**
6.3. Điều kiện trước khi triển khai và hướng phát triển . . . **33**
PHỤ LỤC: KHAI BÁO SỬ DỤNG AI . . . **34**
TÀI LIỆU THAM KHẢO . . . **35**

MỞ ĐẦU

Báo cáo trình bày bài tập lớn học phần Nhập môn học máy FIT4013, đề tài dự đoán sinh viên có nguy cơ bỏ học trên dữ liệu UCI. Nội dung gồm phân tích dữ liệu, thiết kế pipeline, mô tả mã nguồn, thực nghiệm, thảo luận và kết luận theo hướng dẫn học phần.

Nhóm 9: Hoàng Quang Nam (1871020407), Bùi Huy Bình (1871020080), Hoàng Nhật Huy (1871020296), Nguyễn Văn Linh (1871020356).

Chương 1

ĐẶT VẤN ĐỀ VÀ PHÂN TÍCH DỮ LIỆU

1.1 Bối cảnh và mục tiêu

Bỏ học giữa chừng là một vấn đề mà các cơ sở giáo dục cần quan tâm. Khi sinh viên gặp khó khăn về học tập, tài chính hoặc hoàn cảnh cá nhân, việc nhà trường biết sớm có thể giúp việc tư vấn được thực hiện kịp thời hơn. Tuy nhiên, những nguyên nhân này không phải lúc nào cũng thể hiện rõ trong hồ sơ nhập học. Vì vậy, dự đoán bằng học máy chỉ có thể cung cấp thêm một căn cứ để xem xét, chứ không thể thay thế trao đổi trực tiếp với sinh viên.

Kết quả của dự án hướng đến hai nhóm đối tượng chính: (1) **cố vấn học tập và bộ phận hỗ trợ sinh viên** dùng danh sách cảnh báo để ưu tiên tiếp cận sớm; (2) **ban quản lý đào tạo** dùng phân tích lỗi theo ngành và nhóm tuổi để thiết kế chính sách hỗ trợ có mục tiêu. Mô hình được thiết kế như một công cụ sàng lọc bổ trợ, không thay thế phán xét của con người.

Trong bài tập này, nhóm sử dụng bộ dữ liệu *Predict Students' Dropout and Academic Success* do UCI công bố [1]. Mục tiêu là xây dựng chương trình dự đoán trạng thái của một sinh viên khi đến cuối thời hạn chuẩn của khóa học. Dự đoán được đặt tại thời điểm nhập học, nghĩa là mô hình chỉ nên nhận những thông tin có thể biết vào thời điểm đó. Bộ dữ liệu có ba nhãn:

- **Dropout**: sinh viên đã bỏ học.
- **Enrolled**: sinh viên vẫn đang theo học tại thời điểm ghi nhận kết quả.
- **Graduate**: sinh viên đã tốt nghiệp.

Nhóm giữ nguyên ba nhãn thay vì gộp Enrolled vào Dropout. Một sinh viên còn học sau thời hạn chuẩn không nhất thiết sẽ bỏ học; nếu gộp hai trạng thái, kết quả sẽ khó diễn giải hơn và làm thay đổi bài toán gốc.

Ngoài việc xây dựng mô hình, nhóm muốn trả lời hai câu hỏi: thay đổi cách biểu diễn đặc trưng có làm kết quả thay đổi không, và K-NN hay cây quyết định phân loại tốt hơn? Hai luồng dùng cùng 18 cột đầu vào, cùng cách chia và fold; luồng B tạo thêm hai đặc trưng từ các cột này.

1.2 Nguồn và cấu trúc dữ liệu

Bộ dữ liệu được công bố bởi Realinho và cộng sự trên UCI Machine Learning Repository, có mã DOI và được cấp phép CC BY 4.0 [1]. Dữ liệu được tổng hợp từ một cơ sở giáo dục đại học tại Bồ Đào Nha với nhiều ngành học. Mỗi dòng trong tệp tương ứng một sinh viên; các cột gồm thông tin nhân khẩu, quá trình đăng ký, kết quả học tập và trạng thái đầu ra.

Tệp `data.csv` của nhóm có 4.424 dòng và 37 cột, trong đó 36 cột là đặc trưng và cột `Target` là nhãn. Tệp sử dụng dấu chấm phẩy để phân cách các cột. Một điểm cần chú ý khi đọc dữ liệu là tên cột `Daytime/evening attendance` trong CSV gốc có ký tự tab ở cuối. Chương trình loại khoảng trắng ở đầu và cuối tên cột trước khi kiểm tra cấu trúc; nếu tập cột hoặc tập nhãn khác dự kiến, chương trình dừng và báo lỗi.

Theo UCI, bộ dữ liệu đã được xử lý các giá trị thiếu và bất thường trước khi công bố. Do đó, các nhận xét dưới đây chỉ phản ánh tệp đã tải, không phản ánh toàn bộ quá trình làm sạch dữ liệu ban đầu của tác giả. Trong lần kiểm tra của nhóm, tệp không có ô trống và không có dòng trùng hoàn toàn.

Bảng 1.1 tóm tắt ý nghĩa và loại sử dụng của 18 cột đầu vào; các biến phân loại được lưu dưới dạng số nguyên. Bảng tiếp theo liệt kê từng cột còn lại và kiểu lưu trong CSV.

Bảng 1.1. Ý nghĩa và kiểu dữ liệu các cột chính

Tên cột	Kiểu	Mô tả
Application order	Số nguyên	Thứ tự nguyện vọng (0 = ưu tiên nhất)
Previous qualification (grade)	Thực	Điểm văn bằng trước (thang 0–200)
Admission grade	Thực	Điểm tuyển sinh (thang 0–200)
Age at enrollment	Số nguyên	Tuổi lúc nhập học
Marital status	Phân loại	Tình trạng hôn nhân (mã số UCI)
Application mode	Phân loại	Hình thức đăng ký (mã số UCI)
Course	Phân loại	Mã ngành học
Daytime/evening attendance	Phân loại	Ca học (1 = ban ngày, 0 = tối)
Previous qualification	Phân loại	Loại bằng trước khi nhập học
Nacionality	Phân loại	Quốc tịch
Mother’s qualification	Phân loại	Trình độ học vấn của mẹ
Father’s qualification	Phân loại	Trình độ học vấn của cha
Mother’s occupation	Phân loại	Nghề nghiệp của mẹ
Father’s occupation	Phân loại	Nghề nghiệp của cha
Displaced	Phân loại	Chuyển nơi ở (1 = có, 0 = không)
Educational special needs	Phân loại	Nhu cầu giáo dục đặc biệt
Gender	Phân loại	Giới tính (1 = nam, 0 = nữ)
International	Phân loại	Sinh viên quốc tế (1 = có, 0 = không)
Target	Phân loại	Nhãn: Dropout / Enrolled / Graduate

Phân loại là vai trò logic; trong CSV, các mã này là số nguyên. Target là chuỗi. Các cột còn lại được liệt kê ở bảng tiếp theo.

Bảng 1.2. Ý nghĩa và kiểu dữ liệu 18 cột không dùng làm đầu vào

Tên cột	Kiểu CSV	Ý nghĩa
Debtor	int64	Mã tình trạng nợ
Tuition fees up to date	int64	Mã tình trạng học phí
Scholarship holder	int64	Mã tình trạng học bổng
Curricular units 1st sem (credited)	int64	Số học phần được công nhận, học kỳ 1
Curricular units 1st sem (enrolled)	int64	Số học phần đã đăng ký, học kỳ 1
Curricular units 1st sem (evaluations)	int64	Số lần đánh giá, học kỳ 1

Tên cột	Kiểu CSV	Ý nghĩa
Curricular units 1st sem (approved)	int64	Số học phần đã hoàn thành, học kỳ 1
Curricular units 1st sem (grade)	float64	Điểm học kỳ, học kỳ 1
Curricular units 1st sem (without evaluations)	int64	Số học phần không có đánh giá, học kỳ 1
Curricular units 2nd sem (credited)	int64	Số học phần được công nhận, học kỳ 2
Curricular units 2nd sem (enrolled)	int64	Số học phần đã đăng ký, học kỳ 2
Curricular units 2nd sem (evaluations)	int64	Số lần đánh giá, học kỳ 2
Curricular units 2nd sem (approved)	int64	Số học phần đã hoàn thành, học kỳ 2
Curricular units 2nd sem (grade)	float64	Điểm học kỳ, học kỳ 2
Curricular units 2nd sem (without evaluations)	int64	Số học phần không có đánh giá, học kỳ 2
Unemployment rate	float64	Tỷ lệ thất nghiệp
Inflation rate	float64	Tỷ lệ lạm phát
GDP	float64	Tổng sản phẩm quốc nội

1.3 Phân bố nhãn

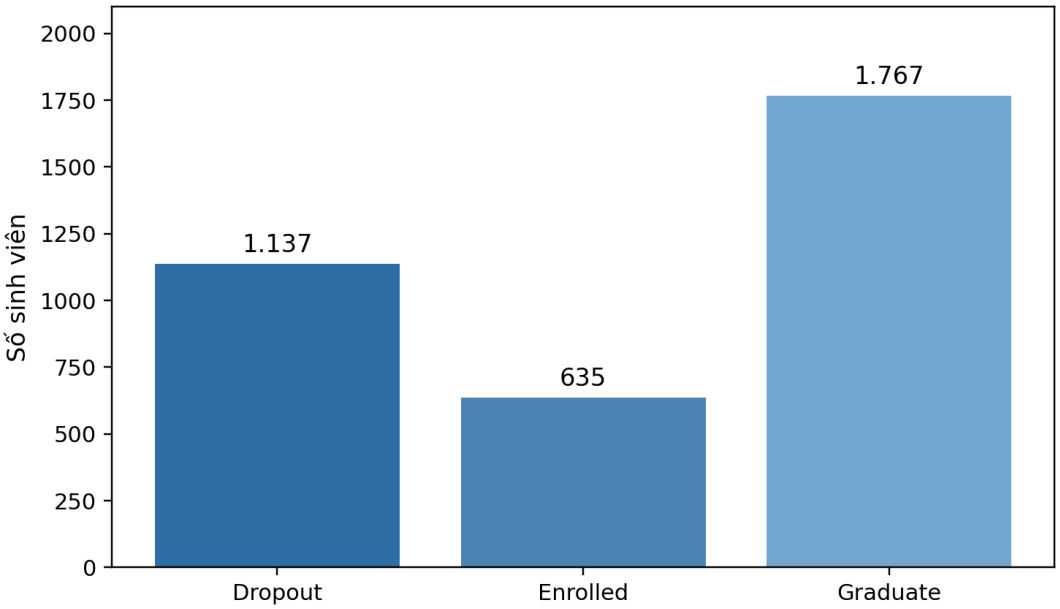
Bảng 1.3 trình bày số lượng của từng lớp trên toàn bộ dữ liệu và sau khi chia train/test. Nhóm chia phân tầng theo nhãn để tỷ lệ các lớp giữa hai tập không chênh lệch quá nhiều.

Bảng 1.3. Số lượng mẫu của từng lớp

Nhãn	Toàn bộ	Tỷ lệ toàn bộ	Train	Test
Dropout	1.421	32,1%	1.137	284
Enrolled	794	17,9%	635	159
Graduate	2.209	49,9%	1.767	442
Tổng	4.424	100%*	3.539	885

* Các tỷ lệ được làm tròn riêng.

Lớp Graduate chiếm gần một nửa dữ liệu, trong khi Enrolled chỉ chiếm khoảng 18%. Sự mất cân bằng này ảnh hưởng đến cách đánh giá: một mô hình thiên về Graduate có thể đạt accuracy không thấp nhưng vẫn dự đoán kém hai lớp còn lại. Vì vậy, bên cạnh accuracy, nhóm theo dõi precision, recall và F1 cho từng lớp, đặc biệt là recall của Dropout.



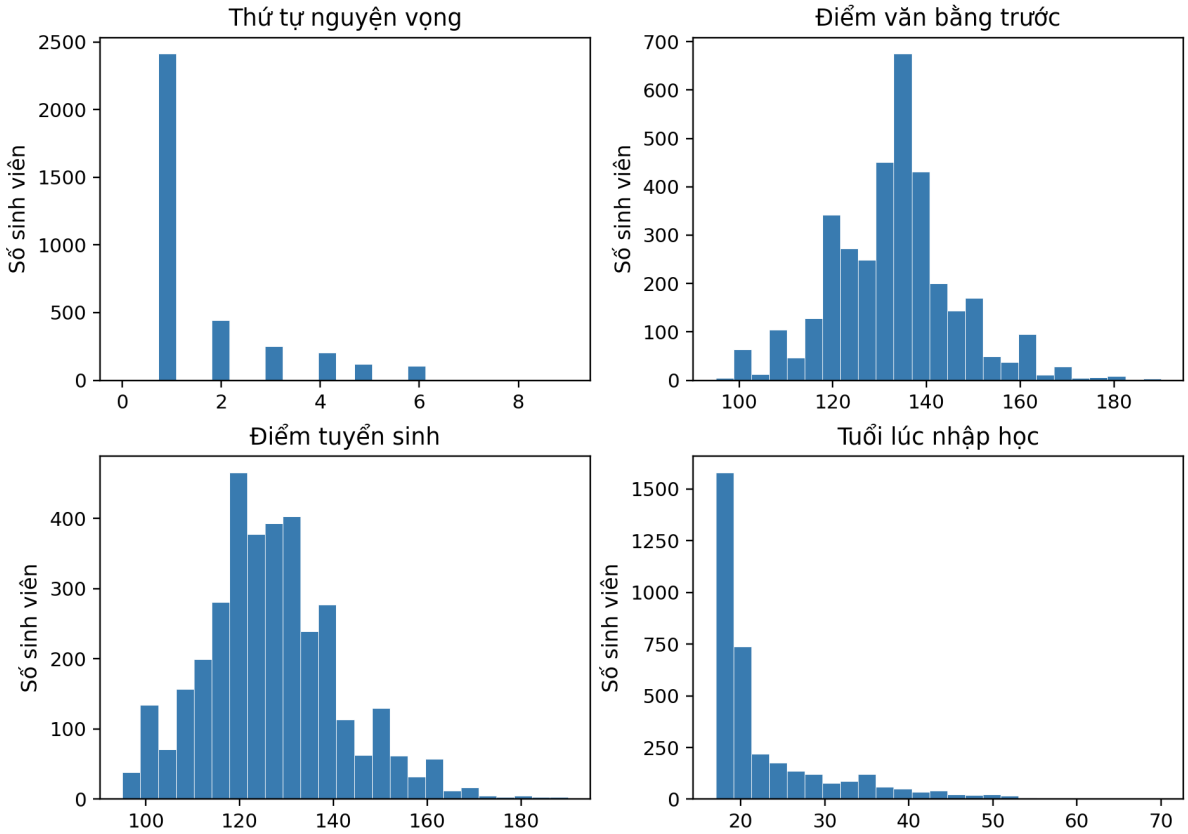
Hình 1.1. Phân bố nhãn trên tập huấn luyện

1.4 Khám phá các đặc trưng

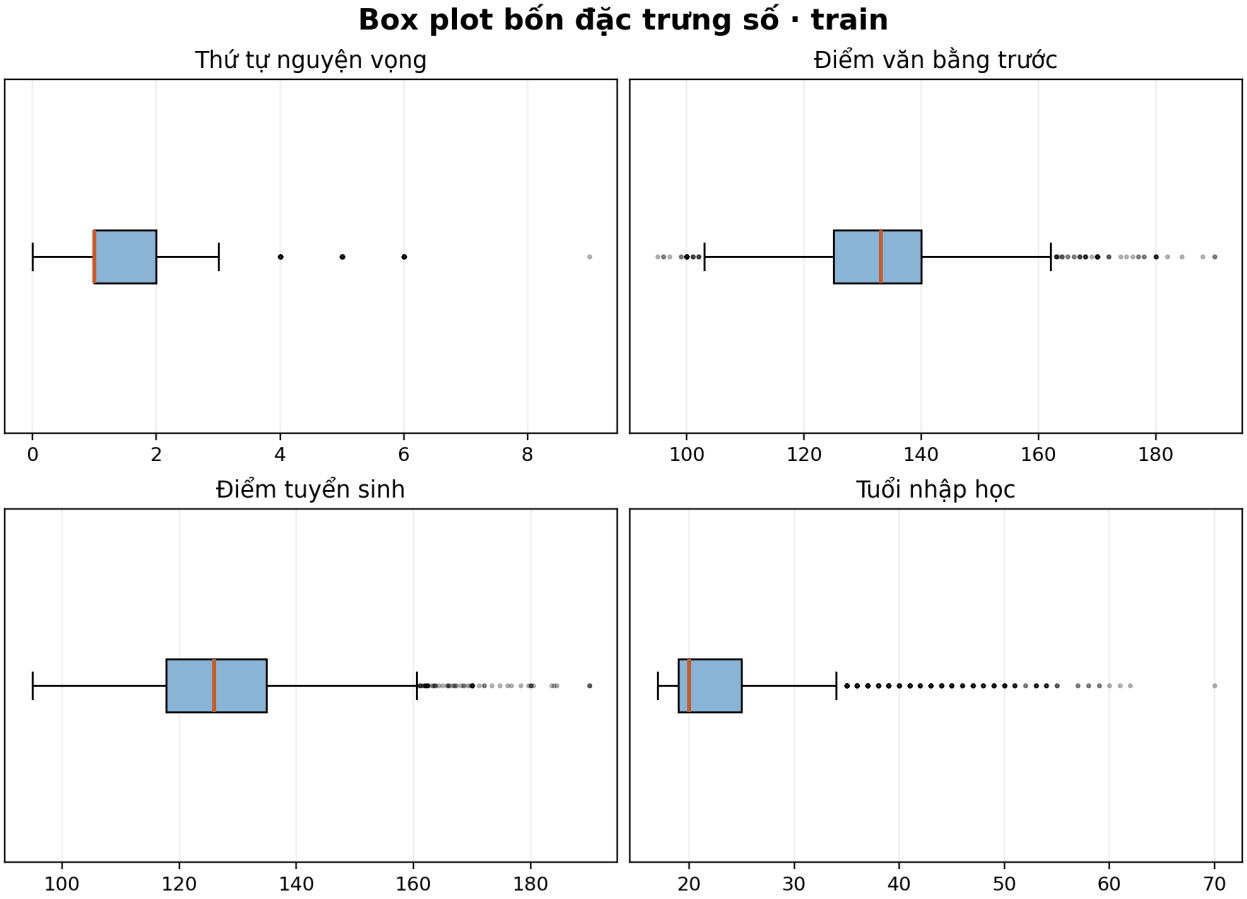
1.4.1 Biến số

Với các biến số được sử dụng, nhóm xem giá trị nhỏ nhất, lớn nhất, trung vị, tứ phân vị và hình dạng phân phối trên tập train. Tuổi nhập học có trung vị 20, tứ phân vị thứ nhất là 19, tứ phân vị thứ ba là 25; giá trị nhỏ nhất và lớn nhất lần lượt là 17 và 70. Điều này cho thấy phần lớn sinh viên trong mẫu vào học ở độ tuổi tương đối trẻ, nhưng cũng có một nhóm nhập học ở độ tuổi lớn hơn.

Nhóm dùng quy tắc $1{,}5 \times IQR$ để đánh dấu các giá trị nằm xa khoảng tứ phân vị. Trên tập train, số giá trị bị đánh dấu là 431 ở thứ tự nguyện vọng, 135 ở điểm văn bằng trước, 68 ở điểm tuyển sinh và 358 ở tuổi nhập học. Đây là dấu hiệu cần xem xét, không tự động là lỗi. Chẳng hạn, sinh viên lớn tuổi hơn vẫn là một trường hợp có thể xảy ra; vì vậy nhóm không xóa các dòng này.



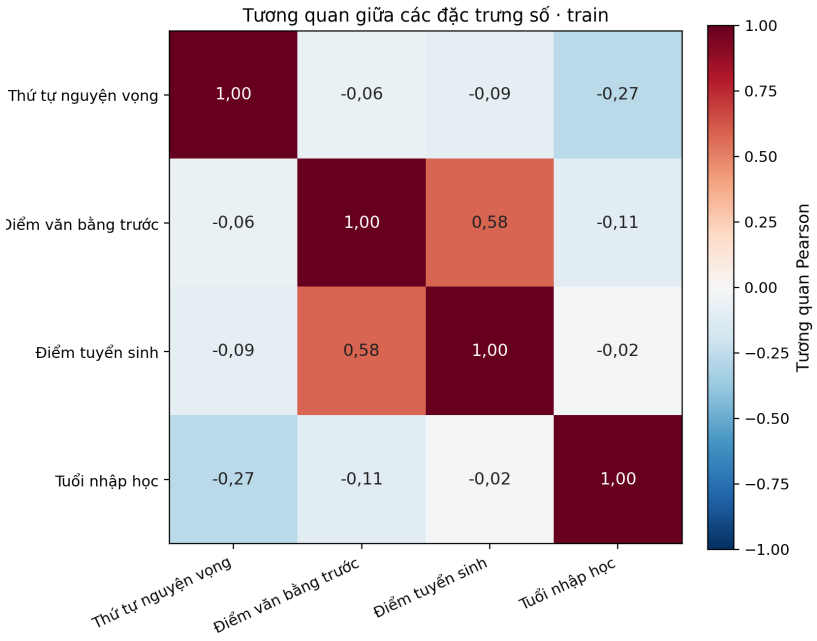
Hình 1.2. Phân phối các biến số được chọn trên tập train



Hình 1.3. Box plot các biến số trên tập train; vạch màu là trung vị, hộp là khoảng IQR; râu tới điểm quan sát xa nhất trong ngưỡng $1{,}5 \times$ IQR, chấm là ngoại lệ.

1.4.2 Tương quan giữa các biến số

Điểm văn bằng trước và điểm tuyển sinh có hệ số tương quan Pearson khoảng 0,581 trên train. Hai biến có liên hệ cùng chiều ở mức vừa trong tập này, nhưng tương quan không chứng minh biến này gây ra biến kia. Tuổi và thứ tự nguyện vọng có tương quan khoảng $-0{,}270$. Nhóm giữ cả bốn biến số vì những thống kê này chưa đủ căn cứ để loại bỏ biến nào.



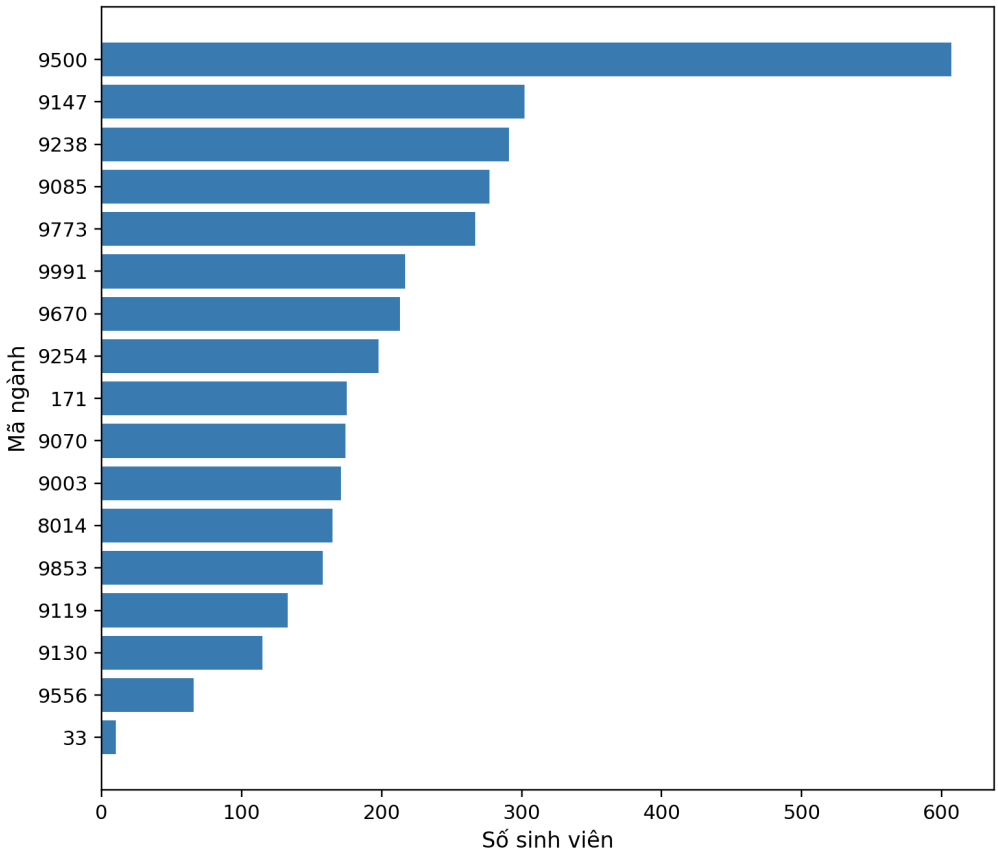
Hình 1.4. Heatmap tương quan Pearson giữa 4 biến số (tập train). Giá trị trong ô là hệ số tương quan.

Bảng 1.4. Ma trận tương quan Pearson giữa 4 biến số (tập train)

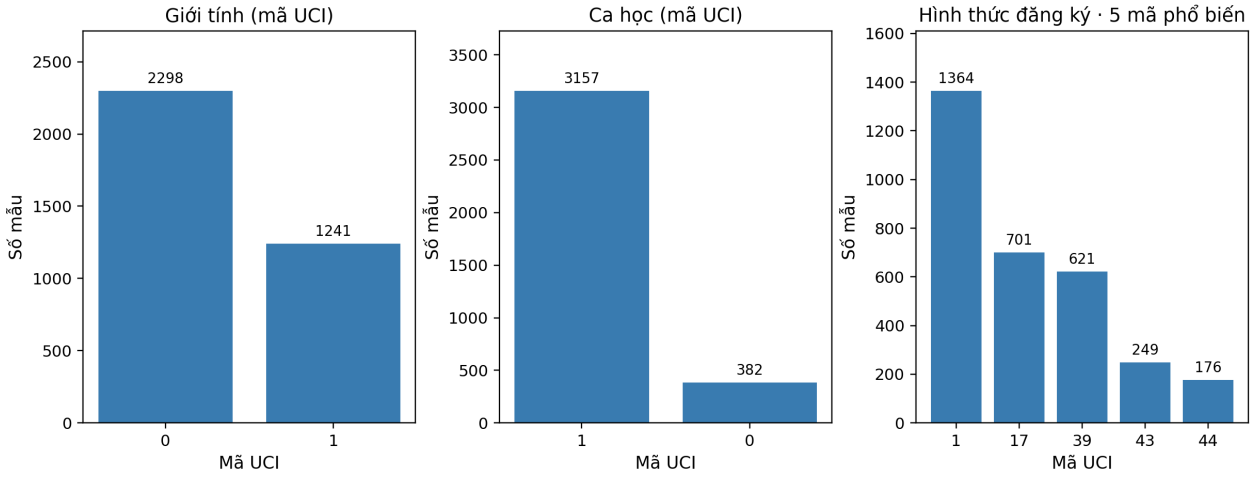
	App.Order	Prev.Grade	Adm.Grade	Age
Application order	1,000	−0,064	−0,092	−0,270
Previous grade	−0,064	1,000	0,581	−0,112
Admission grade	−0,092	0,581	1,000	−0,019
Age at enrollment	−0,270	−0,112	−0,019	1,000

1.4.3 Biến phân loại

Các cột phân loại cần được hiểu theo ý nghĩa, không theo kiểu lưu trữ. Ví dụ, `Course` được lưu dưới dạng số nhưng đó là mã ngành, không phải một đại lượng có thể so sánh hơn kém. Trong tập train, mã ngành 9500 có 607 mẫu; các ngành còn lại có số lượng khác nhau như Hình 1.5. Mã hiếm cung cấp ít ví dụ hơn cho mô hình học, nhất là khi chia thành nhiều fold.



Hình 1.5. Số mẫu theo mã ngành trong tập train



Hình 1.6. Phân bố các biến phân loại chính (tập train): giới tính, ca học và hình thức đăng ký (top 5 mã). Nhãn cột ghi số lượng mẫu tương ứng.

1.5 Thông tin thiếu và giới hạn của dữ liệu

Không có ô trống không đồng nghĩa với việc mọi thông tin đều đầy đủ. Trong bảng mã UCI, giá trị 34 ở trình độ của cha hoặc mẹ có nghĩa là không rõ; tệp có 130 trường hợp ở cột của mẹ và 112 ở cột của cha. Giá trị 99 ở nghề nghiệp được mô tả là trống; số lần xuất

hiện tương ứng là 17 và 19. Các con số này đếm từng cột nên không được cộng trực tiếp để suy ra số sinh viên khác nhau.

Trong chương trình, các mã trên được giữ như một nhóm phân loại riêng, không bị thay bằng giá trị phổ biến nhất. Cách này tránh tự đoán thông tin chưa biết, nhưng cũng có thể khiến mô hình học cả đặc điểm của quá trình thu thập dữ liệu. Nhóm ghi nhận đây là hạn chế, không khẳng định cách xử lý này tốt nhất khi chưa có thí nghiệm bổ sung.

Tập dữ liệu được lấy từ một cơ sở giáo dục, vì vậy kết quả không thể tự động đại diện cho các trường khác. Trong tập train còn có những nhóm nhỏ: 86 sinh viên có mã quốc tế và 41 sinh viên có mã nhu cầu giáo dục đặc biệt. Những nhóm ít mẫu cần được nghiên cứu cẩn thận hơn nếu muốn đánh giá mô hình theo từng nhóm; bài tập hiện chưa thực hiện đánh giá công bằng đó.

1.6 Phân tích cột gây rò rỉ nhãn

Một rủi ro quan trọng khi đặt bài toán dự đoán tại thời điểm nhập học là rò rỉ thông tin tương lai (data leakage): đưa vào mô hình những cột chỉ có thể biết *sau* khi sinh viên đã bắt đầu hoặc kết thúc quá trình học. Nhóm loại bỏ 12 cột học kỳ chưa có lúc nhập học và 6 cột có thời điểm ghi nhận chưa được xác nhận:

- **Kết quả học kỳ 1 và 2** (12 cột: số tín chỉ đã công nhận, đã đăng ký, đã đánh giá, đã hoàn thành, điểm trung bình và số tín chỉ không đánh giá của từng học kỳ): các thông tin này chỉ phát sinh sau khi sinh viên đã theo học ít nhất một hoặc hai kỳ; đưa vào sẽ biến bài toán thành dự đoán *sau sự kiện*.
- **Debtor** (nợ học phí): phát sinh trong quá trình học tập; không xác định được thời điểm ghi nhận trong hồ sơ nhập học.
- **Tuition fees up to date** (tình trạng cập nhật học phí): phụ thuộc vào quá trình đóng học phí định kỳ sau khi đã nhập học.
- **Scholarship holder** (học bổng): nhiều trường hợp học bổng được xét duyệt sau khi đã có kết quả xét tuyển hoặc trong quá trình học.
- **Unemployment rate, Inflation rate, GDP**: thời điểm ghi nhận hoặc công bố của các chỉ số này chưa được xác nhận so với thời điểm dự đoán; chúng bị loại theo nguyên tắc thận trọng.

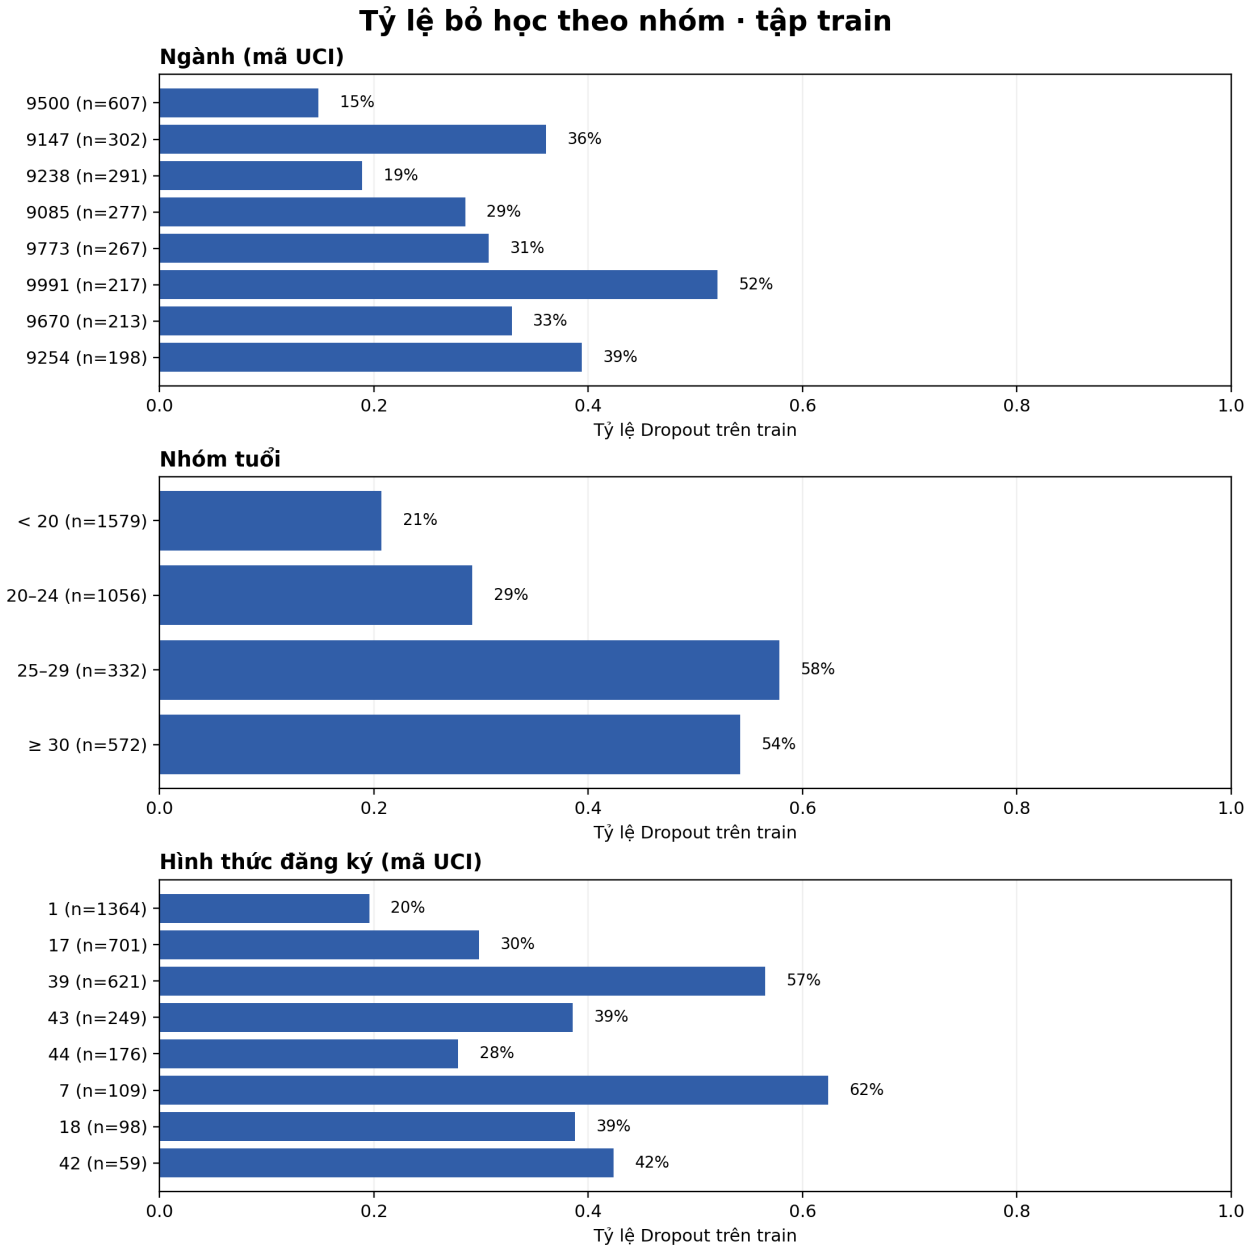
Để minh chứng tác động thực tế của rò rỉ thông tin, nhóm thực hiện thí nghiệm so sánh trực tiếp trên cùng tập train với 5-fold CV phân tầng (giữ nguyên mô hình Cây quyết định mặc định không giới hạn độ sâu):

- **Khi sử dụng toàn bộ 36 đặc trưng** (bao gồm các cột học kỳ và tài chính): Macro-F1 CV đạt $0{,}6265 \pm 0{,}0143$ (accuracy CV $0{,}6869$).
- **Khi chỉ sử dụng 18 đặc trưng nhập học** (không dùng 18 cột được liệt kê): Macro-F1 CV giảm xuống $0{,}4241 \pm 0{,}0205$.

Chênh lệch 0,2024 điểm macro-F1 cho thấy toàn bộ 18 cột bổ sung chứa thông tin dự báo. Thí nghiệm thêm cả 18 cột cùng lúc nên không quy riêng mức tăng cho học kỳ hay học phí. Đối với dự đoán lúc nhập học, cột học kỳ là thông tin tương lai; thời điểm của các cột còn lại cần xác minh. Độ lệch sau dấu $\pm$ là độ lệch chuẩn giữa năm fold, không phải khoảng tin cậy. Kịch bản 36 cột chỉ để minh họa và không dùng lựa chọn mô hình.

1.7 Quan hệ đặc trưng và nhãn trên train và giả thuyết ban đầu

Hình 1.7 thể hiện tỷ lệ Dropout trong các nhóm ngành, độ tuổi và hình thức đăng ký trên tập train (kèm số lượng mẫu tương ứng).



Hình 1.7. Tỷ lệ Dropout theo nhóm trên tập train (ngành và hình thức đăng ký hiển thị các mã phổ biến nhất).

Từ phân tích trực quan này, nhóm hình thành các giả thuyết ban đầu cho việc kỹ thuật đặc trưng và mô hình hóa:

1. **Giả thuyết về độ tuổi nhập học**: Sinh viên dưới 20 tuổi có tỷ lệ Dropout thấp nhất (20,7% với 327/1.579 mẫu), trong khi nhóm 20–24 tuổi là 29,2% và nhóm 25–29 tuổi lên tới 57,8% (192/332 mẫu). Áp lực việc làm hoặc gia đình là giả thuyết cần kiểm tra thêm; dữ liệu hiện tại không xác nhận nguyên nhân này. Do đó, việc chia nhóm tuổi (`age_band`) có thể cung cấp ngưỡng phân tách phi tuyến tốt hơn cho mô hình.
2. **Giả thuyết về ngành học**: Tỷ lệ bỏ học có sự phân hóa mạnh giữa các ngành: ví dụ mã ngành 9500 (Điều dưỡng) có tỷ lệ bỏ học thấp (khoảng 14,8%), trong khi mã

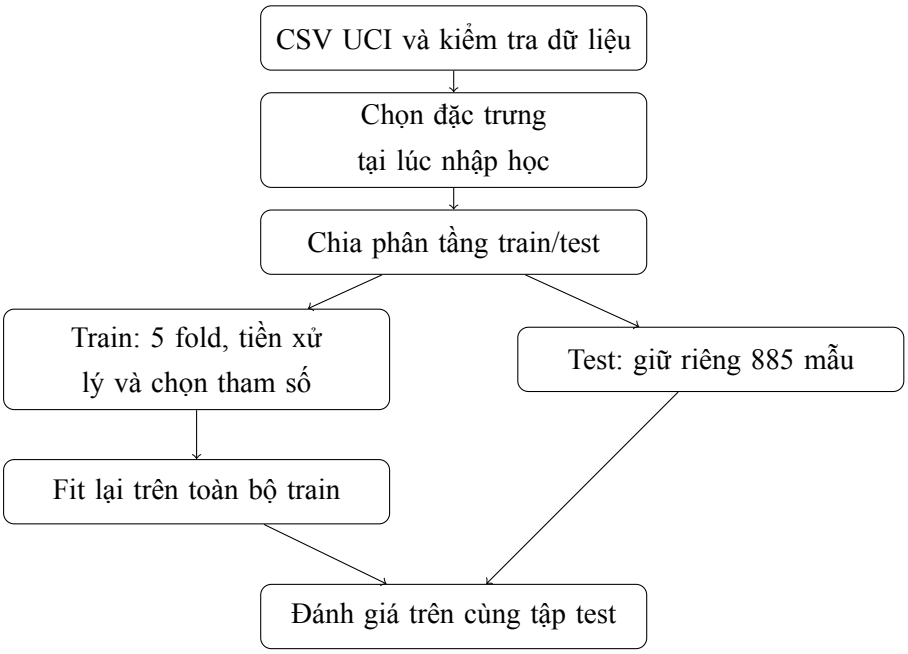
ngành 9147 (Quản lý) có tỷ lệ bỏ học khoảng 36,1%. Sự khác biệt gợi ý khảo sát thêm vai trò ngành; không chứng minh ngành gây ra bỏ học.

3. **Giả thuyết về chênh lệch điểm số**: Mối tương quan 0,581 giữa điểm tuyển sinh và điểm văn bằng trước cho thấy xu hướng chung, nhưng các trường hợp chênh lệch âm lớn (điểm tuyển sinh thấp hơn đáng kể so với điểm học bạ trước đó) có thể phản ánh khác biệt giữa hai lần đánh giá; nguyên nhân chưa được xác minh. Biến hiệu số (`Admission grade - Previous grade`) được đề xuất để nắm bắt yếu tố này.

Chương 2

THIẾT KẾ GIẢI PHÁP VÀ QUY TRÌNH HỌC MÁY

Quy trình chung của bài tập được trình bày ở Sơ đồ 2.1. Sau khi kiểm tra dữ liệu và tách tập, các bước chọn tham số chỉ dùng phần train. Tập test không tham gia chọn tham số bằng CV (xem Mục 2.2).



Sơ đồ 2.1. Quy trình xử lý và đánh giá của nhóm

2.1 Thời điểm dự đoán và lựa chọn đặc trưng

Bài toán được xác định là dự đoán trạng thái học tập của sinh viên tại thời điểm làm thủ tục nhập học; phạm vi này cần được giảng viên xác nhận theo hướng dẫn học phần. Việc xác định thời điểm dự đoán quyết định trực tiếp danh sách đặc trưng được phép sử dụng. Các biến liên quan đến kết quả học tập ở trường đại học (điểm học kỳ 1 và 2) hay biến động tài chính phát sinh sau nhập học (nợ phí, cập nhật học phí) đều bị loại bỏ để tránh dùng thông tin sau thời điểm dự đoán; thời điểm ghi nhận các biến được giữ lại vẫn cần xác nhận (như đã phân tích ở Mục 1.6).

Danh sách 18 cột được chọn thủ công theo thời điểm dự đoán; EDA sau đó dùng để mô tả, không phải thuật toán chọn biến:

- **4 biến định lượng**: Thứ tự nguyện vọng, điểm văn bằng trước, điểm xét tuyển và tuổi lúc nhập học. Các biến đều có biến thiên trên train; tương quan giữa hai biến

điểm là 0,581, nhưng riêng hệ số này không chứng minh tác dụng dự báo của từng biến.

- **14 biến phân loại**: Tình trạng hôn nhân, Hình thức đăng ký, Ngành học, Ca học, Loại văn bằng trước, Quốc tịch, Trình độ và nghề nghiệp của cha mẹ (4 cột), Tình trạng chuyển nơi ở, Nhu cầu giáo dục đặc biệt, Giới tính, và Sinh viên quốc tế. Các biến này mô tả một phần thông tin nhân khẩu và lộ trình trước nhập học; thời điểm ghi nhận từng trường vẫn cần xác minh.

2.2 Chia dữ liệu và kiểm soát rò rỉ

Toàn bộ dữ liệu (4.424 dòng) được phân chia thành 80% tập huấn luyện (3.539 mẫu) và 20% tập kiểm thử (885 mẫu) bằng phương pháp phân tầng theo nhãn, với tham số ngẫu nhiên cố định `random_state = 42`. Chỉ số dòng được lưu trữ trong `train_indices.csv` và `test_indices.csv` để đảm bảo đối chiếu phép chia.

Trong tập huấn luyện, nhóm thiết lập kiểm định chéo 5 fold phân tầng với seed 42 và xáo trộn trước khi chia. Việc cố định bộ fold này đảm bảo mọi mô hình và mọi cấu hình tiền xử lý đều được đánh giá trên cùng tập mẫu con, loại bỏ nhiễu do phân chia ngẫu nhiên khác nhau.

Để chống rò rỉ thông tin trong quy trình huấn luyện, mọi thao tác tính toán tham số thống kê (như tính trung vị để điền khuyết, học từ điển one-hot, tính giá trị trung bình μ và độ lệch chuẩn σ để chuẩn hóa) đều được đóng gói nghiêm ngặt bên trong `Pipeline` của scikit-learn. Quá trình kiểm định chéo chỉ thực hiện `fit` trên 4 fold huấn luyện và `transform` trên fold kiểm định (validation fold). Test không được dùng trong GridSearchCV, nhưng đã được xem trong các lần phát triển trước; do đó đây không còn là tập kiểm thử cuối cùng độc lập.

2.3 Hai luồng tiền xử lý (Luồng A và Luồng B)

Để trả lời câu hỏi nghiên cứu của đề bài: *"Thay đổi cách chuẩn bị dữ liệu có làm đổi hiệu quả mô hình không, và tại sao?"*, nhóm thiết kế hai luồng tiền xử lý có sự khác biệt rõ rệt về kỹ thuật đặc trưng và mức độ xử lý phân loại:

- **Luồng A (Baseline Pipeline)**:
  - *Biến số*: Điền thiếu bằng trung vị, chuẩn hóa bằng `StandardScaler` để đưa về phân phối có $\mu = 0, \sigma = 1$.

- *Biến phân loại*: Điền thiếu bằng giá trị xuất hiện nhiều nhất, mã hóa one-hot thông thường (bỏ qua mã chưa gặp). Mọi giá trị danh mục đều được giữ nguyên và tạo thành cột nhị phân riêng biệt.

- **Luồng B (Feature-Engineered Pipeline)**:

  - *Gộp mã hiếm*: Biến phân loại sau khi điền thiếu được mã hóa one-hot có kèm ngưỡng tần suất `min_frequency = 0.01` (mã mới được ghép vào nhóm hiếm nếu nhóm đó tồn tại). Các hạng mục xuất hiện dưới 1% trong tập huấn luyện của fold sẽ được gộp chung vào một nhóm hiếm. Kỹ thuật này giảm số cột one-hot, nhưng gộp các nhóm khác nhau và có thể làm mất thông tin.
  - *Trích xuất đặc trưng mới dựa trên giả thuyết EDA*:
    1. `age_band`: Nhóm tuổi rời rạc hóa (< 20, 20–24, 25–29, ≥ 30) mã hóa thành một cột số thứ tự 0–3 rồi chuẩn hóa, không one-hot. Với K-NN, đây là bản biến đổi đơn điệu theo bậc của tuổi đã có, làm thay đổi trọng số khoảng cách theo tuổi.
    2. Hiệu hai điểm: Hiệu số giữa điểm tuyển sinh và điểm văn bằng trước. Đại lượng này biểu diễn chênh lệch giữa hai điểm; không trực tiếp đo áp lực hay nguyên nhân học tập.
  - Hai đặc trưng dẫn xuất cũng được chuẩn hóa theo trung bình và độ lệch chuẩn.

2.4 Không gian siêu tham số và thuật toán sử dụng

Nhóm khảo sát hai thuật toán phân loại cốt lõi với nguyên lý hoạt động bổ trợ lẫn nhau:

1. **K láng giềng gần nhất (K-NN)**: Hoạt động dựa trên hình học không gian khoảng cách giữa các điểm dữ liệu. Không gian siêu tham số khảo sát gồm:
   - Số láng giềng $k \in \{5, 11, 21\}$: khảo sát từ phạm vi cục bộ đến khái quát hóa rộng.
   - Trọng số biểu quyết `weights` $\in$ {'uniform', 'distance'}: biểu quyết đều hoặc ưu tiên mẫu ở gần hơn.
   - Độ đo khoảng cách $p \in \{1, 2\}$: khoảng cách Manhattan ($p = 1$) và Euclid ($p = 2$).
2. **Cây quyết định (Decision Tree)**: Hoạt động dựa trên các quy tắc phân nhánh trực giao. Mô hình được khởi tạo với `random_state = 42` để đảm bảo tính nhất quán của thuật toán chia ngẫu nhiên. Không gian siêu tham số khảo sát gồm:

- Độ sâu tối đa `max_depth` $\in \{3, 8, 12\}$: kiểm soát độ phức tạp và chống quá khớp.
- Số mẫu tối thiểu ở nút lá `min_samples_leaf` $\in \{1, 10\}$: tạo ràng buộc làm mịn cây.
- Trọng số lớp `class_weight` $\in$ {None, 'balanced'}: cân nhắc xử lý sự mất cân bằng giữa lớp Enrolled (18%) và Graduate (50%).

2.5 Các độ đo đánh giá và tiêu chí tối ưu

Với bài toán 3 lớp mất cân bằng, chỉ số Accuracy tổng thể dễ bị sai lệch bởi lớp đa số (Graduate chiếm 49,9%). Do đó, nhóm sử dụng:

- **Macro-averaged F1 (Macro-F1)**: Trung bình số học không trọng số của F1-score trên cả 3 lớp:

$$\text{Macro-F1} = \frac{\text{F1}_{\text{Dropout}} + \text{F1}_{\text{Enrolled}} + \text{F1}_{\text{Graduate}}}{3}.$$

  Đây là tiêu chí mục tiêu duy nhất (`refit='macro_f1'`) dùng trong `GridSearchCV` để lựa chọn siêu tham số tối ưu.

- **Recall của lớp Dropout**: Tỷ lệ phát hiện đúng các sinh viên thực sự có nguy cơ bỏ học ($TP/(TP + FN)$). Đây là chỉ số nghiệp vụ mang tính sống còn đối với nhà trường.

- Ngoài ra, ma trận nhầm lẫn đầy đủ (3×3) được theo dõi cho từng mô hình để đánh giá chi tiết dòng chuyển dịch lỗi giữa các cặp nhãn.

Chương 3

PHÂN TÍCH MÃ NGUỒN VÀ CHỨC NĂNG

3.1 Cấu trúc chương trình

Nhóm tách chương trình thành các mô-đun độc lập theo nguyên tắc đơn nhiệm; các mô-đun nghiệp vụ chính nằm trong gói `student_success/`, các kịch bản thực thi nằm trong `scripts/`, giao diện người dùng nằm trong `app.py` và chuỗi sổ tay nghiên cứu nằm trong `notebooks/`. Cấu trúc các tệp chính được tổng hợp trong Bảng 3.1.

Bảng 3.1. Các tệp và thư mục chính của dự án

Tệp / Thư mục	Chức năng
`data.py`	Đọc CSV, kiểm tra tính toàn vẹn lược đồ, xuất bản kiểm kê (`audit.json`) và phân chia train/test phân tầng.
`preprocess.py`	Xây dựng hai luồng tiền xử lý (A và B) bằng `ColumnTransformer` tích hợp trích xuất đặc trưng dẫn xuất.
`train.py`	Tạo 5 fold phân tầng, thiết lập `GridSearchCV` tối ưu siêu tham số, xuất ma trận nhầm lẫn và kết quả CV.
`evaluate.py`	Đánh giá mô hình trên tập test, tính toán bộ chỉ số (Accuracy, Precision, Recall, Macro-F1) và lưu dự đoán.
`verify_results.py`	Kịch bản độc lập kiểm tra rò rỉ fold, tính nhất quán của chỉ số dòng và xác thực lại toàn bộ số liệu.
`download_data.py`	Tự động tải bộ dữ liệu chính thức từ kho lưu trữ UCI về thư mục chỉ định.
`app.py`	Ứng dụng web tương tác xây dựng bằng Streamlit phục vụ trình diễn dự đoán đơn lẻ, dự đoán hàng loạt và giải thích kết quả.
`notebooks/`	Chuỗi 9 Jupyter Notebook (từ `00_du_lieu.ipynb` đến `08_kiem_tra_ket_luan.ipynb`) ghi lại chi tiết từng bước thực nghiệm tuần tự.

3.2 Đọc và kiểm tra dữ liệu

Hàm `load_data` trong `data.py` chịu trách nhiệm kiểm tra tính hợp lệ của tệp nguồn:

- Đọc tệp CSV với dấu phân cách chấm phẩy, loại bỏ khoảng trắng thừa ở tiêu đề (đặc

biệt xử lý ký tự tab ở cột `Daytime/evening attendance`).

- Kiểm tra lược đồ: bảo đảm có đúng 37 cột dự kiến và các nhãn hợp lệ (`Dropout`, `Enrolled`, `Graduate`). Nếu sai lệch lược đồ hoặc nhãn thiếu/không hợp lệ, hàm dừng và báo lỗi; ô thiếu ở đặc trưng được chuyển cho imputer trong pipeline.
- Tự động sinh tệp `audit.json` chứa mã băm SHA-256 của tệp nguồn, số lượng dòng, kiểu dữ liệu và số lượng mẫu của từng lớp, phục vụ đối chiếu kết quả.

3.3 Xây dựng pipeline và trích xuất đoạn mã then chốt

Để ngăn chặn hoàn toàn rò rỉ dữ liệu giữa tập huấn luyện và tập kiểm định, quy trình tiền xử lý được xây dựng hoàn toàn bằng `ColumnTransformer` và đóng gói trong `Pipeline` của scikit-learn.

3.3.1 Xây dựng bộ tiền xử lý với ColumnTransformer

Đoạn trích dưới đây cho thấy cách ghép các nhánh trong ColumnTransformer; ba pipeline con được cấu hình trong `preprocess.py`:

```
# Trich tu build_preprocessor(flow):
# numeric, categorical va engineered da duoc cau hinh o tren
transformers = [('numeric', numeric, NUMERIC),
                ('categorical', categorical, CATEGORICAL)]
if flow == 'B':
    transformers.append(('engineered', engineered,
        ['Age at enrollment', 'Admission grade',
         'Previous qualification (grade)']))
return ColumnTransformer(transformers)
```

3.3.2 Tối ưu hóa siêu tham số với GridSearchCV

Đoạn mã dưới đây (trích từ `student_success/train.py`) thể hiện việc kết hợp Pipeline tiền xử lý với mô hình phân loại và thực hiện kiểm định chéo 5 fold phân tầng:

```
# Thiet lap Pipeline ket hop bo tien xu ly va bo phan loai
pipe = Pipeline([
    ('preprocess', build_preprocessor(flow)),
    ('model', estimator)
])

# GridSearchCV tim kiem tren 5 fold phan tang da co dinh
```

```
search = GridSearchCV(
    pipe, grid, cv=cv,
    scoring={'macro_f1': 'f1_macro', 'dropout_recall': scorer},
    refit='macro_f1', n_jobs=1, return_train_score=False
)
search.fit(X.loc[train_idx], y.loc[train_idx])
```

Việc đặt bộ tiền xử lý bên trong `Pipeline` đảm bảo mỗi fold validation trong quá trình CV được đối xử hoàn toàn như dữ liệu mới: các tham số μ, σ và từ điển mã hóa one-hot chỉ được học trên 4 fold huấn luyện của vòng lặp đó.

3.4 Cách kiểm tra kết quả và ứng dụng demo

Kịch bản `scripts/verify_results.py` thực hiện kiểm toán độc lập:

1. Xác minh tập train (3.539 mẫu) và test (885 mẫu) không có phần tử giao nhau.
2. Đảm bảo 5 fold kiểm định chéo bao phủ chính xác tập train mà không bị trùng lặp.
3. Đọc trực tiếp các tệp dự đoán CSV đã xuất để tính toán lại ma trận nhầm lẫn và các chỉ số, đối chiếu chéo với các tệp JSON kết quả.

Ứng dụng web trong `app.py` (triển khai qua Streamlit) cung cấp giao diện trực quan cho phép người dùng chọn bất kỳ tổ hợp mô hình nào trong 4 tổ hợp đã huấn luyện để dự đoán cho hồ sơ sinh viên mới hoặc tải lên tệp danh sách hàng loạt, và các điểm đầu ra theo lớp; ứng dụng không giải thích nguyên nhân của từng dự đoán.

Chương 4

THỬ NGHIỆM VÀ KẾT QUẢ

4.1 Các mô hình Baseline đối chứng

Để đánh giá chính xác giá trị gia tăng của các kỹ thuật tinh chỉnh và tiền xử lý, nhóm thiết lập ba mốc đối chứng (baseline) theo đúng khuyến nghị của hướng dẫn học phần:

1. **Baseline lớp đa số (Zero-R / Majority Class)**: Dự đoán mọi mẫu đều thuộc lớp `Graduate` (chiếm 49,9% dữ liệu huấn luyện). Mốc này đạt Accuracy $0{,}4994$ trên tập kiểm thử nhưng Macro-F1 chỉ đạt $0{,}2221$, và hoàn toàn bất lực trong việc cảnh báo nguy cơ bỏ học (Recall Dropout bằng $0{,}0000$).

2. **Baseline K-NN mặc định (Default K-NN)**: Sử dụng cấu hình tiêu chuẩn của scikit-learn ($k = 5$, trọng số biểu quyết đều, khoảng cách Euclid $p = 2$) kết hợp với Luồng A cơ bản (không tinh chỉnh siêu tham số). Trên 5-fold CV, mô hình đạt Macro-F1 $0{,}4401 \pm 0{,}0140$; trên tập test đạt Accuracy $0{,}4972$ và Macro-F1 $0{,}4126$.

3. **Baseline Cây quyết định mặc định (Default Decision Tree)**: Cây phát triển tự do không giới hạn độ sâu (`max_depth=None`), tiêu chí Gini, không trọng số lớp. Trên 5-fold CV mô hình đạt Macro-F1 $0{,}4241 \pm 0{,}0205$; trên tập test đạt Accuracy $0{,}4825$ và Macro-F1 $0{,}4347$.

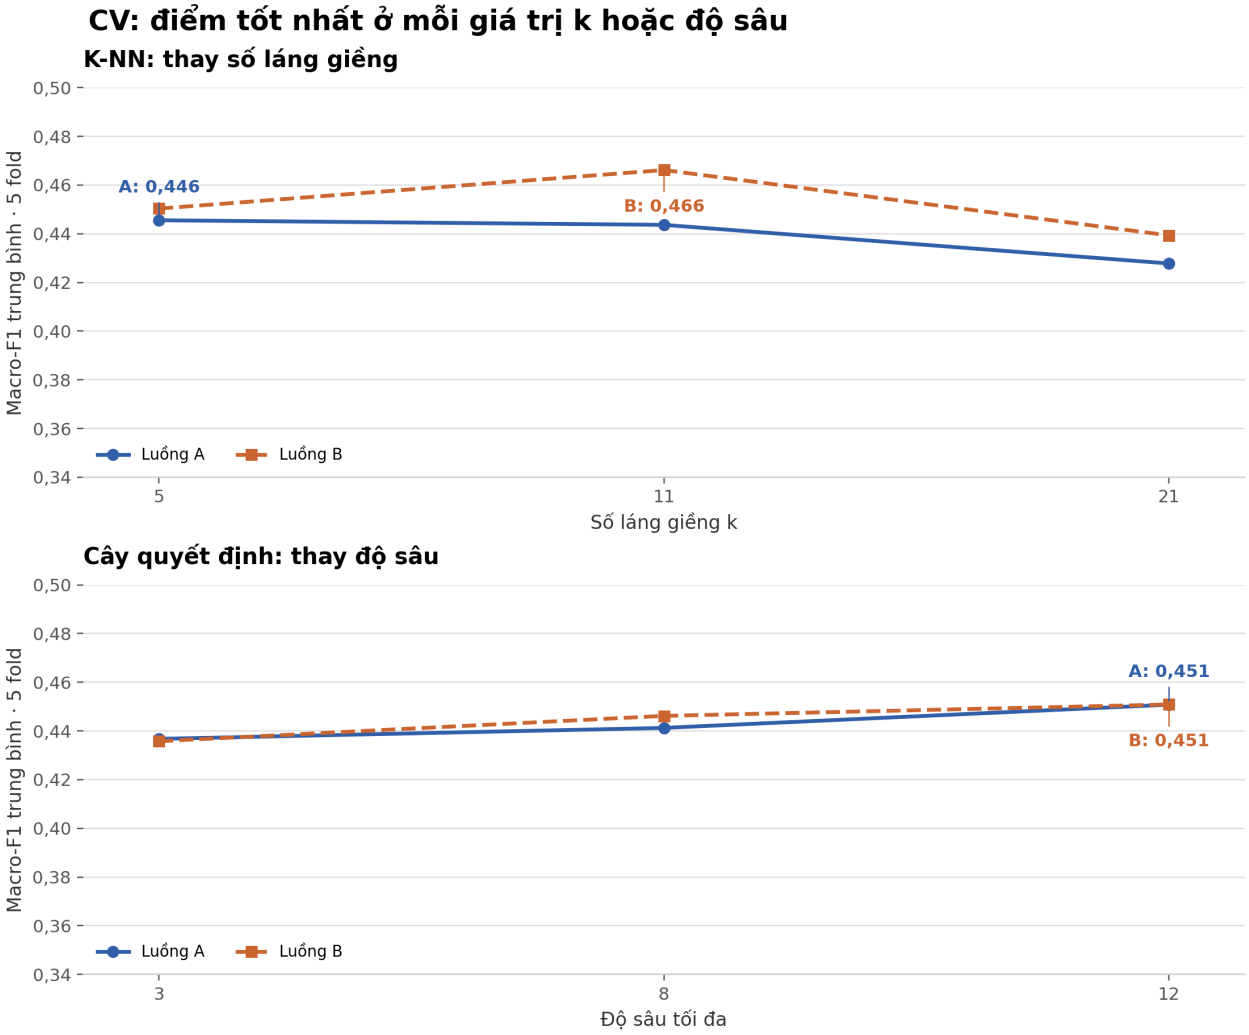
Mức tăng CV của A/K-NN khi tinh chỉnh (0,4401 lên 0,4455) nhỏ hơn độ lệch chuẩn fold của baseline (0,0140). Trên tập test, macro-F1 sau tinh chỉnh là 0,3955, thấp hơn baseline 0,4126.

4.2 Kết quả kiểm định chéo và lựa chọn siêu tham số

Cả bốn tổ hợp thử nghiệm chính được huấn luyện trên 3.539 mẫu train với cùng bộ 5 fold phân tầng. Không gian siêu tham số được duyệt đầy đủ bằng `GridSearchCV` theo tiêu chí tối đa hóa Macro-F1 CV. Cấu hình được chọn và điểm số kiểm định chéo được trình bày trong Bảng 4.1. Phép thử bổ sung giữ nguyên các tham số khác của B/cây cho macro-F1 CV 0,4508 với Gini và 0,4544 với entropy; chênh lệch 0,0036 nhỏ hơn độ lệch chuẩn giữa các fold; entropy là khảo sát phụ, nên lưới chính giữ Gini.

Bảng 4.1. Cấu hình siêu tham số tối ưu chọn theo 5-fold CV trên tập train

Tổ hợp	Siêu tham số tối ưu được chọn	Macro-F1 CV
A / K-NN	$k = 5$; khoảng cách Manhattan ($p = 1$); trọng số đều (`uniform`)	0,4455
A / Cây	`max_depth=12`; `min_samples_leaf=10`; `class_weight=None`	0,4508
B / K-NN	$k = 11$; khoảng cách Manhattan ($p = 1$); trọng số đều (`uniform`)	0,4661
B / Cây	`max_depth=12`; `min_samples_leaf=1`; `class_weight='balanced'`	0,4508



Hình 4.1. Macro-F1 CV theo từng giá trị k (K-NN) và độ sâu `max_depth` (Cây quyết định); các siêu tham số còn lại được tối ưu trong lưới.

Từ Hình 4.1 và Bảng 4.1, tổ hợp **B / K-NN** đạt Macro-F1 CV cao nhất (0,4661), cao hơn Baseline K-NN mặc định (0,4401) và A / K-NN (0,4455). Cấu hình được chọn dùng khoảng cách Manhattan; kết quả này không đủ để khẳng định Manhattan luôn ổn định hơn

Euclid.

4.3 Kết quả trên tập test

Bảng 4.2 tổng hợp kết quả toàn diện của các mô hình baseline và 4 tổ hợp thử nghiệm trên cùng 885 mẫu test. Giới hạn của tập test được nêu ở Mục 2.2.

Bảng 4.2. So sánh tổng hợp các mô hình trên tập kiểm thử (885 mẫu)

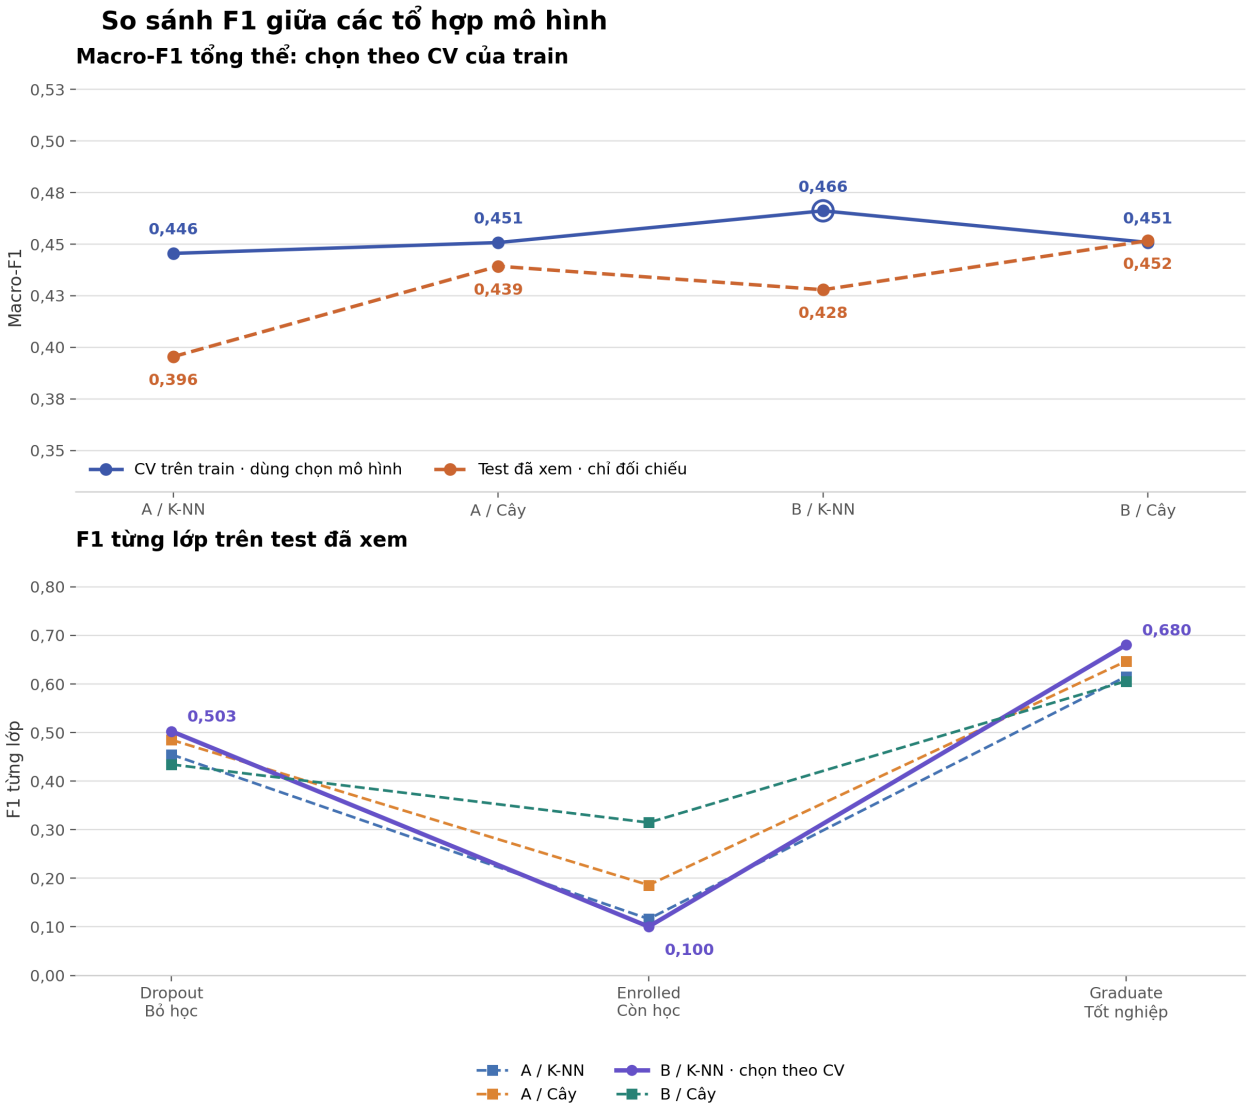
Mô hình / Tổ hợp	Accuracy	Precision (M)	Recall (M)	Macro-F1	Recall Dropout
Baseline đa số (Zero-R)	0,4994	0,1665	0,3333	0,2221	0,0000
Baseline K-NN mặc định	0,4972	0,4179	0,4151	0,4126	0,4401
Baseline Cây mặc định	0,4825	0,4343	0,4358	0,4347	0,4366
A / K-NN (tối ưu)	0,4904	0,3944	0,4024	0,3955	0,4613
A / Cây (tối ưu)	0,5277	0,4451	0,4423	0,4393	**0,4859**
B / K-NN (tối ưu)	**0,5548**	0,4400	0,4417	0,4279	0,4754
B / Cây (tối ưu)	0,4938	**0,4622**	**0,4573**	**0,4517**	0,3732

Precision (M) và Recall (M) ký hiệu cho giá trị trung bình vĩ mô (macro-averaged).

Bảng 4.3 chi tiết hóa hiệu năng từng lớp trên tập kiểm thử.

Bảng 4.3. Precision, Recall và F1-score theo từng lớp trên tập test

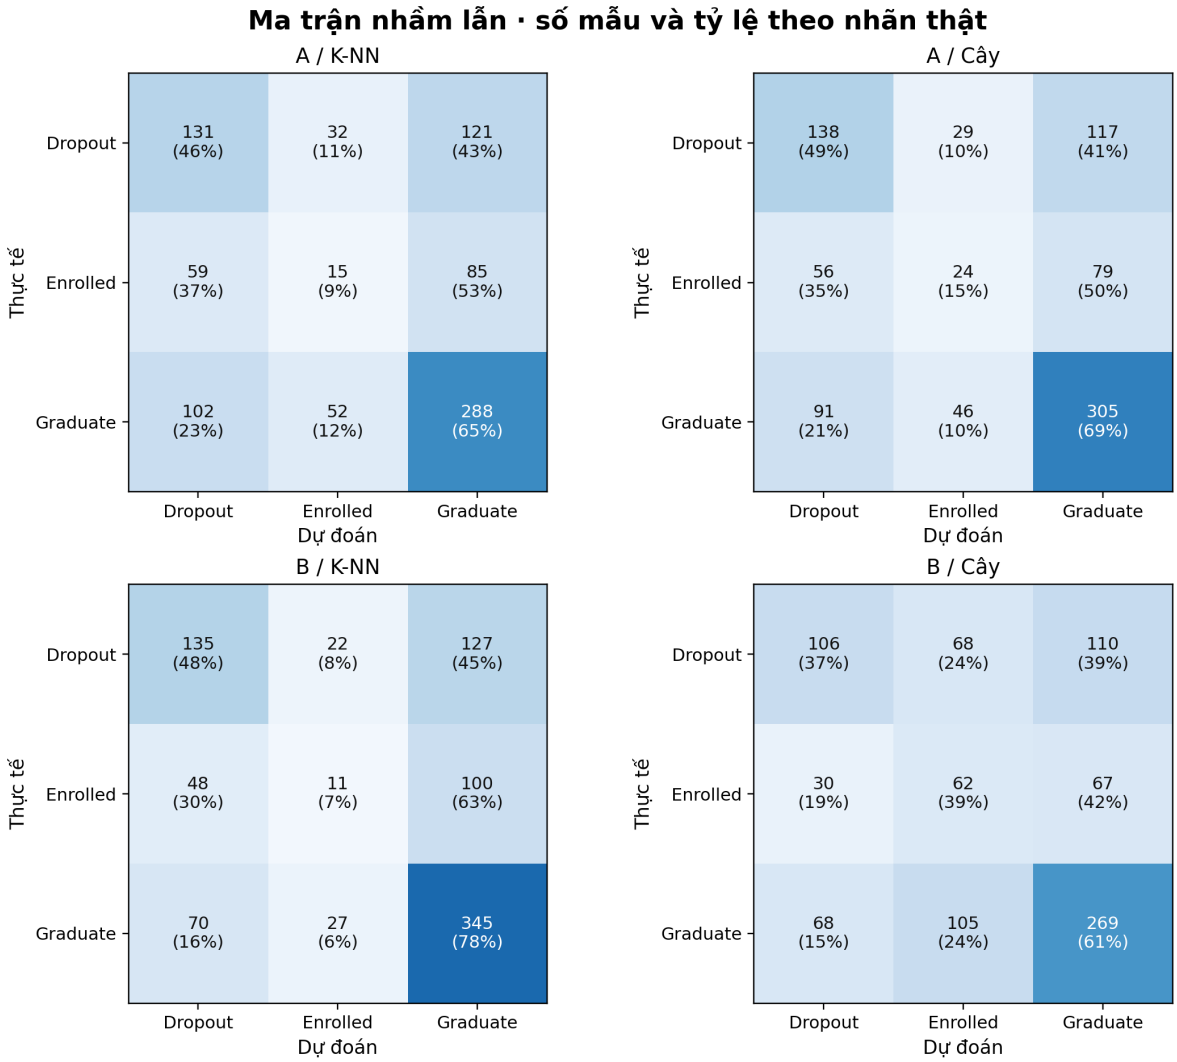
Tổ hợp	Lớp	Precision	Recall	F1-score	Số mẫu thực
A / K-NN	Dropout	0,4486	0,4613	0,4549	284
	Enrolled	0,1515	0,0943	0,1163	159
	Graduate	0,5830	0,6516	0,6154	442
A / Cây	Dropout	0,4842	0,4859	0,4851	284
	Enrolled	0,2424	0,1509	0,1860	159
	Graduate	0,6088	0,6900	0,6469	442
B / K-NN	Dropout	0,5336	0,4754	0,5028	284
	Enrolled	0,1833	0,0692	0,1005	159
	Graduate	0,6031	0,7805	0,6805	442
B / Cây	Dropout	0,5196	0,3732	0,4344	284
	Enrolled	0,2638	0,3899	0,3147	159
	Graduate	0,6031	0,6086	0,6059	442



Hình 4.2. So sánh Macro-F1 và F1-score từng lớp giữa các tổ hợp thử nghiệm.

4.4 Phân tích Ma trận nhầm lẫn đầy đủ và kiểm tra đối chứng

Hình 4.3 hiển thị ma trận nhầm lẫn trực quan của cả bốn tổ hợp thử nghiệm trên cùng 885 mẫu test (trong mỗi ô, số trên là số đếm thực tế, số dưới là tỷ lệ phần trăm theo hàng thực tế).



Hình 4.3. Ma trận nhầm lẫn của 4 tổ hợp thử nghiệm trên tập test (hàng: nhãn thực, cột: dự đoán).

4.4.1 Precision và Recall của lớp Dropout

Với A/cây, precision Dropout là $138/285$ và recall là $138/284$. Hai giá trị gần nhau vì số dự đoán Dropout gần bằng số Dropout thực tế.

4.4.2 Phân tích dòng chuyển dịch lỗi giữa các lớp

Ma trận nhầm lẫn bộc lộ hai quy luật dự đoán quan trọng:

1. **Khó khăn cố hữu của lớp Enrolled**: Cả A / K-NN và B / K-NN đều gặp khó khăn rất lớn trong việc nhận diện sinh viên đang theo học (Enrolled). Ở B / K-NN, chỉ có 11/159 sinh viên Enrolled được phát hiện đúng (Recall 6,92%); có tới 100/159 sinh viên Enrolled bị mô hình dự đoán nhầm thành Graduate và 48 sinh viên bị nhầm thành Dropout.

2. **Khác biệt của hai cấu hình cây**: Khi Cây quyết định được áp dụng trọng số lớp nghịch đảo tần suất trong Luồng B, số lượng Enrolled được nhận diện chính xác tăng vọt từ 24 mẫu (ở A / Cây) lên 62 mẫu (ở B / Cây), kéo Recall của Enrolled từ 15,09% lên 38,99%. Hai cấu hình đồng thời khác cả tiền xử lý, trọng số lớp và tham số; không thể quy mức thay đổi này riêng cho trọng số lớp. Cấu hình B/cây nhạy với quá trình lựa chọn (Mục 5.1.1), vì vậy chênh lệch này chỉ mô tả lần chạy đã lưu.

4.5 So sánh Luồng A và Luồng B: Tác động của tiền xử lý

Câu hỏi cốt lõi của bài toán dữ liệu bảng là: *"Thay đổi cách chuẩn bị dữ liệu có làm đổi hiệu quả mô hình không, và tại sao?"*

Kết quả thực nghiệm cho thấy rõ ràng:

- **Đối với K-NN**: B/K-NN cao hơn A/K-NN 0,0206 điểm macro-F1 CV (0,4661 so với 0,4455); accuracy trên tập test lần lượt là 0,5548 và 0,4904. K-NN phụ thuộc vào khoảng cách; ablation trên train ở Mục 4.6 kiểm tra từng thay đổi khi giữ nguyên tham số B.
- **Đối với Cây quyết định**: B/cây có macro-F1 test 0,4517 và nhận diện lớp Enrolled tốt hơn A/cây. Hai cấu hình đồng thời khác về tiền xử lý, trọng số lớp và tham số, vì vậy không thể quy chênh lệch riêng cho một yếu tố.

Thay đổi chuẩn bị dữ liệu làm thay đổi chất lượng quan sát: với K-NN, B tăng macro-F1 CV từ 0,4455 lên 0,4661. Ablation cho thấy bỏ nhóm tuổi giảm 0,0182, bỏ gộp mã hiếm giảm 0,0076 và bỏ hiệu điểm chỉ giảm 0,0007; giả thuyết là hai thay đổi đầu điều chỉnh khoảng cách và giảm nhiễu, cần kiểm chứng độc lập. Với cây, A và B có điểm CV gần bằng nhau; trong ablation chỉ gộp mã hiếm tạo chênh lệch đáng kể về độ lớn (0,0140), chưa chứng minh ý nghĩa thống kê. Thứ hạng độ quan trọng Gini của hiệu điểm (thứ ba) không đồng nghĩa giá trị dự báo ngoài mẫu. Kết luận về B/cây phụ thuộc cấu hình được chọn (xem Mục 5.1.1).

4.6 Ablation trên các fold train

Bảng 4.4 giữ nguyên siêu tham số của từng mô hình B đã chọn và cùng năm fold, rồi bỏ một nhóm biến đổi mỗi lần. Điểm là macro-F1 trung bình trên train; không huấn luyện lại hay lựa chọn theo test. Các so sánh được thực hiện sau khi thiết kế B, là phân tích khám phá trên cùng dữ liệu và không tách biệt mọi tương tác giữa các biến.

Bảng 4.4. Ablation luồng B: macro-F1 trung bình trên 5 fold train

Biến thể	B / K-NN	B / Cây
B đầy đủ	0,4661	0,4508
Không gộp mã hiếm	0,4585	0,4369
Không thêm nhóm tuổi	0,4480	0,4493
Không thêm hiệu hai điểm	0,4655	0,4471
Không thêm cả hai đặc trưng	0,4529	0,4481

Với K-NN đang xét, bỏ nhóm tuổi làm điểm CV giảm 0,0182; bỏ gộp mã hiếm giảm 0,0076; bỏ hiệu hai điểm giảm 0,0007. Với cây, các chênh lệch tương ứng là 0,0016; 0,0140 và 0,0037. Các con số mô tả tác động khi giữ nguyên cấu hình, không chứng minh nguyên nhân hay bảo đảm lặp lại trên dữ liệu khác. Mã và kết quả từng fold được lưu ở `scripts/evidence_analysis.py` và `data/experiment/ablation_cv.csv`.

4.7 Khoảng biến thiên mô tả trên tập test

Nhóm lấy mẫu bootstrap phân tầng 2.000 lần từ các dự đoán cố định, giữ nguyên số mẫu từng lớp; khoảng percentile 95% của macro-F1 là [0,3649; 0,4262] cho A/K-NN, [0,4059; 0,4704] cho A/cây, [0,3981; 0,4576] cho B/K-NN và [0,4174; 0,4830] cho B/cây. So sánh cặp B/K-NN trừ A/K-NN cho chênh lệch 0,0324 với khoảng [0,0052; 0,0592]. Các khoảng của bốn tổ hợp chồng lấn nhiều nên không đủ để xếp hạng; phép so sánh cặp được tính cho B/K-NN trừ A/K-NN có khoảng không chứa 0. Khoảng có điều kiện trên các mô hình đã fit, không tính bất định do huấn luyện hay chọn cấu hình (Mục 2.2).

4.8 ROC-AUC cho cấu hình B/K-NN

Nhóm tính ROC-AUC one-vs-rest theo từng lớp từ điểm đầu ra của B/K-NN. Trên các dự đoán out-of-fold của train, ROC-AUC macro là 0,6640; trên tập test, macro là 0,6433, gồm Dropout 0,6841, Enrolled 0,5774 và Graduate 0,6685. Cấu hình đã được chọn bằng CV trên cùng train trước phép tính out-of-fold nên các điểm train là mô tả sau lựa chọn; giới hạn của tập test nêu tại Mục 2.2. ROC-AUC đánh giá thứ tự điểm theo từng lớp trên nhiều ngưỡng, không chứng minh các điểm đã được hiệu chỉnh xác suất. Kết quả và cách tính nằm trong `data/experiment/B_knn_roc_auc.csv` và `scripts/roc_analysis.py`.

Chương 5

THẢO LUẬN VÀ PHÂN TÍCH LỖI

5.1 So sánh ưu và nhược điểm của các pipeline và mô hình

Bảng 5.1 tổng hợp ưu và nhược điểm của từng phương án tiền xử lý (Luồng A vs Luồng B) và từng thuật toán phân loại (K-NN vs Cây quyết định).

Bảng 5.1. Ưu và nhược điểm của các pipeline tiền xử lý và mô hình phân loại

Thành phần	Ưu điểm	Nhược điểm / Hạn chế
Luồng A (Baseline)	Đơn giản, giữ nguyên mọi giá trị phân loại gốc; không làm mất chi tiết của các mã hiếm; dễ cài đặt.	Tạo ma trận đặc trưng thưa thớt (sparse); dễ bị ảnh hưởng bởi nhiễu từ các nhóm quá ít mẫu; không có đặc trưng phi tuyến mới.
Luồng B (Feature-Engineered)	Giảm số chiều nhiễu nhờ gộp mã hiếm ($< 1\%$); bổ sung 2 đặc trưng miền nghiệp vụ (`age_band`, hiệu hai điểm) được khảo sát bằng ablation trên train.	Mất đi tính phân biệt chi tiết của các nhóm cá biệt; cần giả định chuyên gia khi chia nhóm tuổi và tính hiệu số điểm.
K-NN	Đơn giản, phi tham số, không cần giả định phân phối; đạt Accuracy cao nhất ($55{,}48\%$) trên tập test khi kết hợp với Luồng B.	Rất nhạy cảm với độ đo khoảng cách và biến phân loại one-hot; chi phí tính toán tăng theo kích thước tập train; nhận diện lớp Enrolled rất kém.
Cây quyết định	Khả năng diễn giải tự nhiên thông qua quy tắc rẽ nhánh; cung cấp `feature_importances_`; linh hoạt kết hợp với trọng số lớp cân bằng để cải thiện lớp thiểu số Enrolled.	Dễ bị quá khớp (overfitting) nếu không giới hạn độ sâu; biên quyết định trực giao có thể thô ráp; nhạy cảm với biến động nhỏ của tập train.

5.1.1 Độ nhạy của cây quyết định

Các cấu hình cây có điểm CV gần nhau so với độ lệch giữa các fold, nên lựa chọn cấu hình cần được kiểm tra trên môi trường khác. Trên Python 3.14.6, chạy lại giữ nguyên dự đoán và cấu hình của bốn tổ hợp; với B/cây cố định cấu hình đã chọn, macro-F1 test trung bình

qua seed 0–9 là 0,4505 (độ lệch chuẩn 0,0026). TODO(human): xác minh thí nghiệm môi trường thứ hai trước khi báo cáo kết quả tái lập.

5.2 Phân tích độ quan trọng của đặc trưng (Feature Importances)

Trích xuất thuộc tính `feature_importances_` từ mô hình Cây quyết định B (Bảng 5.2) cho thấy mức độ đóng góp của từng biến vào việc giảm độ hỗn tạp (Gini impurity) qua các điểm chia.

Bảng 5.2. Top 10 đặc trưng quan trọng nhất trong mô hình Cây quyết định (B / Cây)

Thứ hạng	Tên đặc trưng	Độ quan trọng
1	Tuổi lúc nhập học (`Age at enrollment`)	0,1505
2	Điểm xét tuyển (`Admission grade`)	0,1186
3	**Hiệu điểm tuyển sinh và văn bằng trước**	**0,0921**
4	Điểm văn bằng trước (`Previous qualification grade`)	0,0650
5	Mã ngành 9500 (Điều dưỡng)	0,0411
6	Thứ tự nguyện vọng (`Application order`)	0,0307
7	Mã ngành 9238 (Công tác xã hội)	0,0216
8	Trình độ mẹ mã 34 (Không rõ)	0,0199
9	Giới tính nữ (`Gender_0`)	0,0199
10	Mã ngành 9119 (Kỹ thuật thông tin)	0,0155

Mã trình độ mẹ 34 (không rõ) có thể phản ánh quy trình thu thập dữ liệu như đã nêu ở Mục 1.5; giả thuyết này chưa được kiểm tra. Độ quan trọng Gini mô tả mức giảm hỗn tạp trong cây được fit; nó không chứng minh tác động nhân quả hay đóng góp ngoài mẫu:

- Biến do nhóm tự thiết kế — **hiệu hai điểm** — đứng vị trí thứ 3 toàn bộ mô hình (độ quan trọng $0{,}0921$), vượt qua cả điểm văn bằng trước gốc ($0{,}0650$). Chỉ số này không chứng minh sự ổn định của sinh viên; ablation ở Mục 4.6 đánh giá việc bỏ biến trên các fold train.
- **Độ tuổi nhập học** là đặc trưng số 1 ($0{,}1505$). Chỉ số cho thấy biến được dùng trong các phép chia của cây, không xác nhận nguyên nhân bỏ học.

5.3 Phân tích phân bố lỗi theo nhóm nhân khẩu và ngành học

Kiểm tra chi tiết các trường hợp dự đoán sai của mô hình được chọn theo macro-F1 CV (B / K-NN) trên tập test cho thấy tỷ lệ lỗi phân bố không đồng đều giữa các nhóm:

5.3.1 Phân tích lỗi theo nhóm tuổi

- **Nhóm** < 20 **tuổi**: Tỷ lệ dự đoán sai là 42,1% (157/373 mẫu). Đây là tỷ lệ sai thấp nhất trong bốn nhóm tuổi được trình bày.
- **Nhóm 20–24 tuổi**: Tỷ lệ dự đoán sai tăng lên 46,4% (129/278 mẫu).
- **Nhóm 25–29 tuổi**: Tỷ lệ dự đoán sai là 47,4% (45/95 mẫu).
- **Nhóm** ≥ 30 **tuổi**: Tỷ lệ dự đoán sai là 45,3% (63/139 mẫu).

Khác biệt về thành phần lớp, quy mô nhóm hoặc đặc trưng không được quan sát là các giả thuyết cần kiểm tra; không thể suy ra hoàn cảnh hay nguyên nhân của từng sinh viên từ bảng này.

5.3.2 Phân tích lỗi theo ngành học (Course)

- **Ngành 9085** (Thú y): Tỷ lệ sai 28,3% (17/60 mẫu).
- **Ngành 9500** (Điều dưỡng): Tỷ lệ sai 31,4% (50/159 mẫu).
- **Ngành 9773** (Báo chí và Truyền thông): Tỷ lệ sai 35,9% (23/64 mẫu).
- **Ngành 9238** (Công tác xã hội): Tỷ lệ sai 39,1% (25/64 mẫu).
- **Ngành 9147** (Quản lý): Tỷ lệ sai **50,0%** (39/78 mẫu). Các số này chỉ mô tả những ngành được nêu, không chứng minh lý do sai.

5.4 Bản chất khó khăn của lớp sinh viên đang theo học (Enrolled)

Trong cả 4 tổ hợp, lớp `Enrolled` luôn có F1-score thấp nhất (từ $0{,}1005$ đến $0{,}3147$). Nhóm xem xét hai giả thuyết, chưa xác định được nguyên nhân từ các phép đo hiện tại:

1. **Mất cân bằng mẫu**: Lớp Enrolled chỉ chiếm 17,9% toàn bộ tập dữ liệu (159 mẫu trong tập test), ít hơn đáng kể so với Graduate (49,9%) và Dropout (32,1%).
2. **Trạng thái chuyển tiếp (Transitional State)**: Sinh viên "Enrolled" tại thời điểm khảo sát thực chất là những người chưa hoàn thành chương trình đúng thời hạn chuẩn nhưng cũng chưa chính thức làm thủ tục bỏ học. Họ có thể đang trả nợ môn, bảo lưu hoặc học chậm tiến độ. Thông tin nhập học có thể không đủ để phân biệt nhóm này; mức độ chồng lấn đặc trưng cần nghiên cứu thêm.

5.5 Tác động thực tế của các loại sai lầm trong giáo dục

Trong bài toán hỗ trợ sinh viên, hai loại sai lầm dự đoán có chi phí và hệ quả xã hội hoàn toàn bất đối xứng:

- **Bỏ sót sinh viên bỏ học (False Negative – FN)**: Ở mô hình B / K-NN, có 149 sinh viên bỏ học thực tế bị mô hình dự đoán nhầm thành Enrolled (22 mẫu) hoặc Graduate (127 mẫu). Nếu danh sách dự đoán là kênh sàng lọc duy nhất, những người này có thể không được chủ động liên hệ; dữ liệu không cho biết việc hỗ trợ thực tế của họ.
- **Cảnh báo nhầm sinh viên bình thường (False Positive – FP)**: Ở mô hình B / K-NN, có 118 sinh viên (48 Enrolled và 70 Graduate) bị dán nhãn nhầm là có nguy cơ Dropout. Hệ quả của sai lầm này là tốn thời gian và công sức của đội ngũ cố vấn học tập khi phải lên lịch gặp gỡ, trao đổi. Cảnh báo sai có thể gây phiền hà hoặc kỳ thị nếu thông tin bị sử dụng không phù hợp; cần hạn chế truy cập và trao đổi tôn trọng.

Do đó, trong thực tế, nhà trường nên ưu tiên mô hình có Recall Dropout cao (hoặc chủ động hạ ngưỡng quyết định để đón bắt được nhiều sinh viên nguy cơ hơn), chấp nhận một mức tăng vừa phải của cảnh báo sai.

5.6 Giới hạn nghiên cứu

Nhóm ghi nhận một số giới hạn chính của bài nghiên cứu:

1. Dữ liệu thu thập từ một viện giáo dục đại học duy nhất tại Bồ Đào Nha, do đó các quy luật về ngành học và độ tuổi có thể không phản ánh chính xác bối cảnh giáo dục đại học tại Việt Nam.
2. Việc chỉ sử dụng thông tin tĩnh tại thời điểm nhập học tránh các biến học kỳ chưa có tại thời điểm dự đoán nhưng làm giảm thông tin đầu vào; các trường còn lại vẫn cần xác nhận thời điểm ghi nhận.
3. Giới hạn của tập test được trình bày tại Mục 2.2; cần kiểm chứng trên các khóa tuyển sinh tiếp theo.

Chương 6

TỔNG KẾT VÀ KHUYẾN NGHỊ ỨNG DỤNG

6.1 Kết quả và giới hạn

B/K-NN đạt macro-F1 CV cao nhất trong bốn tổ hợp ở lưới chính (0,4661). Trên test, cấu hình này có macro-F1 0,4279, recall Dropout 0,4754 và recall Enrolled 0,0692. B/cây đạt macro-F1 test 0,4517 và recall Enrolled 0,3899, nhưng recall Dropout chỉ 0,3732. Kết quả B/cây phụ thuộc cấu hình được chọn (Mục 5.1.1). Mỗi cấu hình có sự đánh đổi; ưu tiên mô hình cần gắn với mục tiêu hỗ trợ và nguồn lực.

Ablation trên cùng fold cho thấy khi giữ tham số B/K-NN, bỏ nhóm tuổi làm macro-F1 CV giảm 0,0182; bỏ gộp mã hiếm giảm 0,0076. Đây là phép so sánh khám phá sau khi đã chọn cấu hình; cần kiểm tra lại trên dữ liệu khác. Giới hạn của tập test được nêu tại Mục 2.2.

6.2 Đề xuất sử dụng trong bối cảnh nhà trường

Nếu được xác nhận phù hợp với bối cảnh và đánh giá đầy đủ, kết quả dự đoán có thể hỗ trợ cán bộ công tác sinh viên hoặc cố vấn học tập ưu tiên liên hệ tư vấn; dự đoán không tự quyết định học bổng, tình trạng học tập hay việc sinh viên có được hỗ trợ. Danh sách chỉ là một nguồn tham khảo, cần kết hợp thông tin khác và trao đổi trực tiếp với sinh viên.

Cân đối bỏ sót và cảnh báo sai. Với B/K-NN trên test, 149 trong 284 Dropout không được gắn nhãn Dropout và 118 mẫu thuộc lớp khác bị gắn nhãn Dropout. Bỏ sót có thể khiến một người không được chủ động liên hệ nếu chỉ dựa vào danh sách; cảnh báo sai tiêu tốn thời gian tư vấn và có thể tạo cảm giác bị gắn nhãn. Nhà trường cần xác định trước số trường hợp có thể liên hệ, chi phí sai lầm và mục tiêu recall. Nếu nghiên cứu ngưỡng điểm Dropout, cần chọn ngưỡng bằng dữ liệu train/validation và kiểm tra trên tập mới; mô hình ba lớp hiện dự đoán theo lớp có điểm lớn nhất, không dùng ngưỡng mặc định 0,5. Các điểm đầu ra chưa được hiệu chỉnh xác suất.

Quy trình và bảo vệ dữ liệu. Người phụ trách được phân quyền phù hợp xem danh sách, liên hệ kín đáo, xác định nhu cầu thực tế rồi giới thiệu hỗ trợ phù hợp; không suy đoán nguyên nhân cá nhân từ điểm mô hình. Chỉ thu thập dữ liệu cần thiết, phân quyền theo nhiệm vụ, bảo vệ tệp và hạn chế thời gian lưu trữ theo quy định của đơn vị. Mã định danh giả danh vẫn có thể liên kết lại với cá nhân và cần được bảo vệ.

6.3 Điều kiện trước khi triển khai và hướng phát triển

Trước khi thử nghiệm tại một trường, cần xác nhận thời điểm ghi nhận từng biến, sự tương thích của bảng mã và mục đích xử lý dữ liệu; kiểm định trên khóa tuyển sinh mới hoặc dữ liệu độc lập tại trường đó. Theo dõi cả chỉ số theo lớp, nhóm có đủ mẫu và thay đổi phân phối dữ liệu, sau đó rà soát lại khi kết quả suy giảm. Ngưỡng hay khả năng can thiệp chỉ nên được quyết định sau khi thảo luận với người phụ trách thực tế.

Có thể tiếp tục ablation trên các fold train mới hoặc đánh giá kịch bản sau học kỳ 1 như một bài toán riêng với thời điểm dự đoán khác. Bộ dữ liệu chính là UCI 697 theo liên kết của đề tài; phạm vi dự đoán tại thời điểm nhập học cần được giảng viên xác nhận. Chưa có thí nghiệm chứng minh điểm số của kịch bản sau học kỳ 1, do đó không đặt trước giá trị macro-F1 cho kịch bản này.

PHỤ LỤC: KHAI BÁO SỬ DỤNG AI

OpenAI Codex hỗ trợ đọc hướng dẫn, viết mã, chạy thí nghiệm và soạn báo cáo trong các phiên trước và rà soát trước khi nộp. Anthropic Claude rà soát độc lập báo cáo và repository, đề xuất sửa lỗi.

AI hỗ trợ mã, phân tích và văn bản; thành viên phải kiểm tra nội dung, mã, nguồn và kết quả. Mọi số liệu báo cáo lấy từ mã đã chạy trong repository; mỗi thành viên chịu trách nhiệm và phải giải thích được phần của mình. Tự khai công cụ, mục đích và ngày của từng thành viên: TODO(member). Chi tiết trong `AI_USAGE.md`.

TÀI LIỆU THAM KHẢO

[1] V. Realinho, M. V. Martins, J. Machado, L. Baptista (2021), *Predict Students' Dropout and Academic Success*, UCI Machine Learning Repository, https://doi.org/10.24432/C5MC89. Giấy phép CC BY 4.0: https://creativecommons.org/licenses/by/4.0/.

[2] Lê Thị Thùy Trang, *Hướng dẫn thực hiện bài tập lớn học phần Nhập môn học máy*, năm học 2026–2027.